Universidade do Minho
Escola de Engenharia

Joana Margarida Antunes Lopes

Análise de fatores de risco e previsão da doença periodontal com recurso a Machine Learning

outubro de 2025

Universidade do Minho
Escola de Engenharia

Joana Margarida Antunes Lopes

Análise de fatores de risco e previsão da doença periodontal com recurso a Machine Learning

Dissertação de Mestrado
Mestrado em Bioinformática

Trabalho efetuado sob a orientação de:
Professora Doutora Ana Cristina Braga
Professora Doutora Marta Mendonça Moutinho Relvas

outubro de 2025

Direitos de Autor e Condições de Utilização do Trabalho por Terceiros

Este é um trabalho académico que pode ser utilizado por terceiros desde que respeitadas as regras e boas práticas internacionalmente aceites, no que concerne aos direitos de autor e direitos conexos.

Assim, o presente trabalho pode ser utilizado nos termos previstos na licença abaixo indicada.

Caso o utilizador necessite de permissão para poder fazer um uso do trabalho em condições não previstas no licenciamento indicado, deverá contactar o autor, através do RepositóriUM da Universidade do Minho.

Licença concedida aos utilizadores deste trabalho:

CC BY

https://creativecommons.org/licenses/by/4.0/

Agradecimentos

Em primeiro lugar, agradecer ao meu namorado que me incentivou a entrar nesta aventura e a sair da minha zona de conforto. A ele que me fez acreditar que a vida muda na proporção da nossa coragem. Por todas as horas difíceis que acompanharam esta jornada, por todos os conselhos e apoio constante.

À minha mãe, pai e irmão, que sempre demonstraram orgulho pelo meu percurso, sobretudo por nunca baixar os braços. Sem o suporte deles teria sido mais difícil.

Aos meus colegas de trabalho pela paciência nos dias difíceis e pelas trocas de turnos para conseguir estudar. Ao que foi, no decorrer deste Mestrado, o meu Chefe de Serviço de Medicina Interna da Unidade Local de Saúde de Braga, Miguel Cerqueira, pelo horário compatível que sempre me proporcionou e por reconhecer a mais-valia da formação dos profissionais.

Às minhas amigas, Adriana e Sara, pelas palavras de motivação, pela confiança, pelos lanches e pela paciência nos dias de lamentação. Obrigada por estarem incondicionalmente ao meu lado.

Um agradecimento especial à professora Doutora Ana Cristina Braga por toda a disponibilidade demonstrada, pelos desabafos entre reuniões e pelo rigor sempre presente, e à professora Doutora Marta Mendonça Moutinho Relvas pela ajuda neste percurso.

A todos eles, o meu muito obrigada.

Declaração de Integridade

Declaro ter atuado com integridade na elaboração do presente trabalho académico e confirmo que não recorri à prática de plágio nem a qualquer forma de utilização indevida ou falsificação de informações ou resultados em nenhuma das etapas conducente à sua elaboração.

Mais declaro que conheço e que respeitei o Código de Conduta Ética da Universidade do Minho.

Universidade do Minho, Braga, outubro 2025

Joana Margarida Antunes Lopes

Resumo

A Doença Periodontal é uma patologia inflamatória crónica multifatorial que constitui uma das principais causas de perda dentária a nível mundial. O diagnóstico precoce é determinante para evitar complicações, sendo que as abordagens tradicionais apresentam limitações na identificação de indivíduos em risco. A presente dissertação teve como objetivo avaliar a utilização de algoritmos de *Machine Learning* na previsão da Doença Periodontal a partir de dados clínicos, comportamentais, sociodemográficos e moleculares.

Foram analisados dados de 189 indivíduos, incluindo variáveis clínicas, hábitos de higiene oral, consumo tabágico, presença de diabetes e níveis salivares de mediadores inflamatórios. Foram treinados diferentes algoritmos: *Naive Bayes, Decision Tree, Random Forest, Support Vector Machine, K-Nearest Neighbors* e Regressão Logística. O desempenho foi comparado com base em métricas de classificação, destacando-se o modelo de Regressão Logística como um dos mais robustos, aliado à fácil interpretabilidade e aplicação clínica.

Os resultados evidenciaram o papel relevante de fatores clínicos como a percentagem total de placa, profundidade de sondagem e percentagem total de placa, bem como outros fatores como número de dentes, frequência de escovagem, tabagismo e determinados mediadores inflamatórios (IL-1β, IL-6 e IL-8) na previsão da Doença Periodontal. Estes resultados reforçam a utilidade do *Machine Learning* - e, particularmente, da Regressão Logística - como ferramenta complementar para apoio ao diagnóstico e à gestão personalizada da Doença Periodontal.

Concluiu-se que os modelos de *Machine Learning* apresentam potencial promissor na prática clínica, podendo contribuir para o desenvolvimento de estratégias de prevenção direcionadas e de abordagens personalizadas. Futuras investigações devem explorar a integração de *datasets* maiores e mais heterogéneos, bem como a validação externa dos modelos em diferentes contextos clínicos.

Palavras-chave Doença Periodontal, Fatores de Risco, Mediadores Inflamatórios, *Machine Learning*.

Abstract

Periodontal Disease is a chronic, multifactorial inflammatory pathology and constitutes one of the leading causes of tooth loss worldwide. Early diagnosis is crucial to prevent complications, while traditional approaches present limitations in identifying at-risk individuals. This dissertation aimed to evaluate the use of *Machine Learning* algorithms for predicting Periodontal Disease based on clinical, behavioral, sociodemographic, and molecular data.

Data from 189 individuals were analyzed, including clinical variables, oral hygiene habits, tobacco use, presence of diabetes, and salivary levels of inflammatory mediators. Different algorithms were trained: *Naive Bayes, Decision Tree, Random Forest, Support Vector Machine, K-Nearest Neighbors*, and Logistic Regression. Performance was compared using classification metrics, highlighting Logistic Regression as one of the most robust models, combined with its ease of interpretability and clinical applicability.

The results highlighted the significant role of clinical factors such as total plaque percentage, probing depth, and total plaque percentage, as well as other factors such as number of teeth, brushing frequency, smoking, and certain inflammatory mediators (IL-1β, IL-6, and IL-8) in predicting Periodontal Disease. These findings reinforce the utility of *Machine Learning*—and particularly Logistic Regression—as a complementary tool to support diagnosis and personalized management of Periodontal Disease.

It was concluded that *Machine Learning* models show promising potential in clinical practice, potentially contributing to the development of targeted prevention strategies and personalized approaches. Future research should explore the integration of larger and more heterogeneous *datasets*, as well as external validation of the models in different clinical contexts.

Keywords Periodontal Disease, Risk Factors, Inflammatory Mediators, Machine Learning.

Conteúdo

I Material Introdutório e Fundamentação Teórica **1**

1 Introdução **2**

2 Estado da arte **4**

Saúde Oral e Doença Periodontal 4

Fatores de Risco para doença periodontal 11

Tabagismo 11

Diabetes Mellitus 13

Mediadores Inflamatórios na Periodontite 14

Algoritmos de *Machine Learning* 16

Naive Bayes 19

K-Nearest Neighbors 19

Decision Trees 20

Random Forest 20

Support Vector Machine 21

Regressão Logística 21

Machine Learning e previsão da Doença Periodontal 24

II Metodologia, Resultados e Discussão **26**

3 Metodologia **27**

3.1 Recolha de Dados 27

3.2 Análise exploratória e pré-processamento de dados 28

3.3 Mediadores Inflamatórios 30

3.3.1 Tratamento de valores "Below Detection Limit" 30

3.3.2 Teste de normalidade 31

3.3.3 Transformação logarítmica 31
3.4 Preparação do *dataset* para o treino dos algoritmos de ML 31
3.4.1 Definição do *dataset* para ML e Método de Avaliação de Desempenho dos modelos 33
3.5 Tradução do modelo para a Prática Clínica 35

4 Resultados **37**
4.1 Análise exploratória: principais resultados 37
4.2 Avaliação do desempenho dos modelos: Contribuição de todas as variáveis 40
4.3 Avaliação do desempenho dos modelos: Contribuição de um subset de variáveis comuns 45
4.4 Avaliação do desempenho dos modelos: Contribuição de subsets de variáveis específicas para cada modelo 45
4.5 Regressão Logística: Aplicação Clínica 46
4.5.1 Variáveis a incluir 46
4.5.2 Coeficientes e interpretação do modelo 48
4.5.3 *Thresholds de decisão* 49
4.5.4 Receita clínica para aplicação do modelo 49

5 Discussão **54**

III Considerações Finais **58**

6 Conclusão **59**

IV Apêndices **67**

A Parâmetros do Modelo de Regressão Logística **68**

B Ferramentas **69**

Lista de Figuras

Figura 1 O caminho do Cuidado periodontal (adaptado de Bishop (2021)). 8

Figura 2 Estrutura geral da criação de um modelo preditivo baseado em ML, considerando a fase de treino e de teste (adaptado de Sarker (2021)). 17

Figura 3 Ilustração simplificada do algoritmo K-Nearest Neighbors. 19

Figura 4 Ilustração de uma *Decision Tree.* 20

Figura 5 *Workflow* de pré-processamento dos dados. 32

Figura 6 Metodologia adotada para a eleição do melhor modelo com capacidade preditiva clínica. 36

Figura 7 *Heatmaps* de correlação entre os mediadores inflamatórios antes (esquerda) e depois (direita) da imputação dos valores BDL. 38

Figura 8 Distribuição do mediador IL-1β antes e depois da transformação logarítmica (*log1p*). 39

Figura 9 Distribuição do mediador IL-8 antes e depois da transformação logarítmica (*log1p*). 39

Figura 10 Curvas ROC. 41

Figura 11 Matrizes de Confusão dos três modelos com melhor desempenho 42

Figura 12 Análise da importância das *features*: *Random Forest*. 43

Figura 13 Análise da importância das *features*: *Support Vector Machine*. 44

Figura 14 Análise da importância das *features*: *Regressão Logística*. 44

Figura 15 Desempenho do modelo de Regressão Logística (*Top Features*) em diferentes thresholds. 50

Figura 16 Distribuição das probabilidades previstas pelo modelo de Regressão Logística 50

Lista de Tabelas

Tabela 1 Classificação da severidade da Periodontite. 9

Tabela 2 Classificação da progressão da Periodontite em graus. 10

Tabela 3 Resumo das vantagens e desvantagens dos algoritmos de ML. 24

Tabela 4 Resultados do teste de *Mann-Whitney* para os mediadores inflamatórios selecionados. 39

Tabela 5 Distribuição percentual de saúde e DP nos conjuntos de treino e teste. . . 40

Tabela 6 Desempenho dos modelos de classificação e seleção dos melhores modelos. 41

Tabela 7 Desempenho dos modelos considerando diferentes conjuntos de variáveis. 47

Tabela 8 Coeficientes, Odds Ratios e interpretação clínica do modelo de Regressão Logística com Top Features específicas. 49

Tabela 9 Exemplo de processamento dos dados de um paciente 53

Tabela 10 Média e desvio padrão de cada variável usada pelo modelo. 68

Lista de Siglas

AUC *Area Under the Curve*

BDL *Below Detection Limit*

BOP *Bleeding on Probing*

CAL *Clinical Attachment Loss*

DM Diabetes Mellitus

DP Doença Periodontal

FP Falso Positivo

FN Falso Negativo

IA Inteligência Artificial

IFN Interferão

IL Interleucina

LOD *Limit Of Detection*

ML *Machine Learning*

MMP Matriz Metaloproteinase

OR *Odds Ratio*

PI *Plaque Index*

PPD *Periodontal Probing Depth*

RBL *Radiografic Bone Loss*

ROC *Receiver Operating Characteristic Curve*

TNF *Tumor Necrosis Factor*

VP Verdadeiro Positivo

VN Verdadeiro Negativo

Parte I

Material Introdutório e Fundamentação Teórica

Capítulo 1

Introdução

Doença Periodontal (DP) é um termo abrangente que se refere a uma condição que afeta a saúde oral de milhões de pessoas em todo o mundo (Organização Mundial da Saúde, 2023). Desde a inflamação leve das gengivas à destruição do periodonto, a DP pode levar a consequências severas, como a perda dentária e complicações sistémicas. O diagnóstico precoce e a intervenção adequada são fundamentais para a gestão eficaz desta doença. Em 2018, a Academia Americana de Periodontologia e a Federação Europeia de Periodontologia, publicaram e difundiram a Classificação das Doenças e Condições Periodontais e Peri-implantares que ainda hoje se encontra em vigor. As principais formas de DP incluem: condições e doenças gengivais, periodontite e outras condições que afetam o periodonto (Steffens and Marcantonio, 2018).

Vários fatores têm sido apontados como contribuintes para o desenvolvimento e agravamento da DP, incluindo fatores genéticos, comportamentais, ambientais e sistémicos. Entre os fatores mais frequentemente identificados, destacam-se a idade, hábitos tabágicos, higiene oral inadequada, condições sistémicas, como diabetes, e a predisposição genética (Darby, 2022). A interação complexa desses fatores torna o diagnóstico da DP desafiador e, muitas vezes, subestimado até serem atingidos estádios avançados e irreversíveis.

Com o avanço da tecnologia e da ciência de dados, novas abordagens têm sido exploradas para melhorar o diagnóstico precoce da DP, utilizando modelos computacionais baseados em *Machine Learning* (ML). Estes modelos têm o potencial de analisar grandes volumes de dados de forma mais eficiente e precisa, ajudando quer na identificação de pessoas em risco quanto à gestão da doença e ao tratamento.

Partindo do estado da arte, esta dissertação pretende responder de forma clara à seguinte questão de investigação:

> "De que forma os modelos de ML poderão auxiliar no diagnóstico da DP?"

Com base nesta questão, este estudo passa por analisar um conjunto de dados relativos a indivíduos com e sem DP, e delineou-se como objetivo principal avaliar diferentes modelos de ML, utilizando métricas bem definidas, de forma a identificar o modelo mais preciso na identificação da DP com base em diversos fatores de risco, como a idade, hábitos tabágicos, hábitos de higiene oral, presença de condições sistémicas como a diabetes, entre outros.

Os objetivos específicos deste trabalho englobam:

- Executar tarefas de pré-processamento dos dados brutos, em linguagem *Python*, com vista a garantir a qualidade dos dados;
- Executar tarefas de análise exploratória;
- Implementar e treinar diversos modelos de ML;
- Avaliar cada modelo utilizando métricas adequadas, como *Accuracy*, *Recall*, *Precision*, *F1-score*, entre outras.

O resultado esperado vai de encontro à seleção do melhor modelo no que diz respeito à predição da doença periodontal, para posterior implementação numa aplicação computacional/ *software* clínico que possa ser utilizado por profissionais de saúde em Medicina Dentária.

A estrutura desta dissertação organiza-se em três grandes blocos:

- (i) enquadramento teórico, com revisão da literatura sobre saúde oral, fatores de risco, algoritmos de ML e aplicações de ML em periodontologia;
- (ii) metodologia, onde se descrevem os procedimentos de recolha, tratamento e análise de dados, bem como os algoritmos aplicados;
- (iii) apresentação e discussão dos resultados, seguida das considerações finais, onde se destacam as principais conclusões, limitações do estudo e perspetivas de investigação futura.

Capítulo 2

Estado da arte

Neste capítulo será realizada uma revisão abrangente e crítica da literatura existente na área da DP, suportando as tarefas mencionadas, e cuja execução permitirá atingir os objetivos delineados. Inicialmente serão abordados os conceitos de saúde oral e DP, e ainda como estes se relacionam. Os subcapítulos seguintes abordam os fatores de risco para a DP, dando principal destaque à presença de diabetes e ao tabagismo, e o papel dos mediadores inflamatórios na DP. O último subcapítulo visa introduzir o papel do ML na área da saúde, e, particularmente, na DP, destacando aplicações práticas do ML no diagnóstico de DP, bem como limitações e desafios.

Saúde Oral e Doença Periodontal

O Plano Nacional de Saúde 2021-2030 (Direção Geral da Saúde, 2022) destaca a área da saúde oral como um determinante da saúde, particularmente como um problema de saúde de elevada magnitude para o qual são traçadas estratégias de intervenção para combater as necessidades em saúde nesse setor. Uma das estratégias traçadas tem como objetivo a recuperação/melhoria do acesso aos cuidados de saúde oral, incluindo os preventivos.

O conceito de saúde periodontal integra-se no conceito geral de saúde, e é descrito como um estado livre de doenças periodontais inflamatórias, permitindo que um indivíduo funcione normalmente e evite consequências (mentais ou físicas) devido a doenças atuais ou passadas. A saúde periodontal ideal engloba a ausência de doença, avaliada clinicamente, associada a gengivite, periodontite ou outras condições periodontais. Pode incluir também pacientes com histórico de gengivite ou periodontite tratados com sucesso, ou outras condições periodontais, que conseguiram e conseguem manter a sua dentição sem sinais de inflamação gengival clínica. A saúde periodontal clínica inclui vigilância imunológica fisiológica envolvendo níveis de marcadores biológicos e inflamatórios compatíveis com a homeostasia (Chapple et al., 2018).

O conceito de DP é abrangente, englobando um conjunto de condições inflamatórias que afetam os tecidos de suporte dos dentes, incluindo as gengivas, o ligamento periodontal, o cemento radicular e o osso alveolar (Zhang et al., 2024). Esta é primariamente iniciada por biofilmes bacterianos que se acumulam nas superfícies dos dentes, conhecidos como placa bacteriana, desencadeando uma resposta imune-inflamatória do hospedeiro. No entanto, a progressão da doença e a sua gravidade são influenciadas por uma complexa interação de fatores de risco como genética, tabagismo, condições sistémicas como a diabetes, e fatores locais como anatomia dentária e restaurações inadequadas. Ou seja, a DP pode ser entendida como uma interação entre o hospedeiro e o biofilme, na qual o equilíbrio entre os fatores do hospedeiro e os fatores bacterianos determina a progressão da doença (Papapanou et al., 2018) (Chapple et al., 2018).

Estudos reconhecem que a DP não é causada por uma única bactéria dominante, mas sim por um desequilíbrio na estrutura dos biofilmes, alterando o comportamento coletivo do microbioma e permitindo a proliferação de espécies anteriormente benignas, fazendo com que, com o tempo, o biofilme mude a sua composição de bactérias Gram-positivas aeróbicas para bactérias Gram-negativas anaeróbicas (Hasan and Palmer, 2014). O microbioma oral é uma comunidade complexa e dinâmica de microrganismos que residem na cavidade oral, incluindo bactérias, fungos, vírus e outros organismos. Esses microrganismos formam biofilmes que aderem às superfícies dos dentes. Longe de ser uma coleção aleatória de bactérias, o microbioma oral é um ecossistema complexo onde centenas de espécies distintas interagem e cooperam para se adaptarem às condições oscilantes da cavidade oral, como mudanças na disponibilidade de nutrientes, stress mecânico e acidez. Este desequilíbrio desencadeia uma resposta inflamatória que pode levar à degradação dos tecidos de suporte dos dentes, contribuindo para a periodontite. A compreensão do microbioma oral como um ecossistema complexo é crucial para o desenvolvimento de estratégias eficazes de prevenção e tratamento de doenças periodontais (National Institute of Dental and Craniofacial Research, 2024).

Um relatório publicado recentemente pela *Economist Intelligence Units* sobre os custos socioeconómicos da DP mostrou que nos últimos 20 anos, apesar dos avanços nos serviços de saúde oral na Europa e da crescente consciencialização sobre a importância da higiene oral, a prevalência da periodontite tem-se mantido relativamente estável. Esta estabilidade é preocupante, considerando que a periodontite não tratada é a principal causa de perda de dentes e representa uma ameaça significativa para a saúde pública. Acredita-se que os resultados possam ser ainda mais preocupantes dada a limitação na recolha de dados epidemiológicos. Os dados existentes são heterogéneos e inexistentes em alguns países europeus. As

melhores estimativas provêm do estudo *Global Burden of Disease*, que abrange apenas casos graves de periodontite (Bishop, 2021).

Segundo a Organização Mundial de Saúde, estima-se que as doenças periodontais graves afetem cerca de 19% da população adulta global, representando mais de 1 bilião de casos em todo o mundo (Organização Mundial da Saúde, 2023). A nível mundial, os custos diretos de tratamento de doenças dentárias, incluindo periodontite, são estimados em 298 mil milhões de dólares por ano, representando 4,6% dos gastos globais com saúde. Em 2020, os cuidados de saúde oral representaram, em média, 30% dos gastos com saúde nos países europeus da Organização para a Cooperação e Desenvolvimento Económico. As doenças dentárias resultam em 144 mil milhões de dólares anuais em custos indiretos em todo o mundo, comparáveis às 10 doenças globais mais dispendiosas. Na Alemanha, cerca de 30-40% da extração de dentes é devida a doenças periodontais, e isso parece não ter mudado nos últimos 15 anos. No que diz respeito ao nível da qualidade de vida das pessoas com DP, o desconforto pós-operatório e a dor após cirurgias dentárias levam à perda de produtividade, resultando num custo estimado de 54 mil milhões de dólares por ano. No Canadá, problemas dentários resultam em média em 3,5 horas de perda de tempo de trabalho por pessoa por ano, o que equivale a 40 milhões de horas de trabalho perdidas a nível nacional (Bishop, 2021).

A prevenção da periodontite através da gestão da gengivite demonstra ser economicamente vantajosa. Um estudo em creches escocesas demonstrou que a escovagem supervisionada, a fluoretação da água e o fornecimento de escovas e pasta de dentes a crianças de 0 a 5 anos resultaram em economias de cerca de 3 milhões de libras num período de um ano. O programa "*Mouth Care Matters*" implementado no Reino Unido, entre 2015 e 2020, visava melhorar a consciencialização dos profissionais de saúde sobre a ligação entre os cuidados de higiene oral e a saúde geral, prevendo-se que, por cada libra investida no programa, seriam gerados 2,66 libras em benefícios diretos e indiretos para o sistema de saúde e 17 libras em benefícios sociais adicionais. O relatório apresenta ainda um modelo simplificado, criado para representar a progressão da periodontite e as probabilidades de um indivíduo transitar entre diferentes fases de saúde oral e etapas de tratamento, mostra que um indivíduo com gengivite tem uma probabilidade de 5% de progredir para periodontite a cada ciclo de 4 meses. Para além disso, 95% dos indivíduos com gengivite que recebem tratamento, 50% retornam ao estado saudável. Isto significa que, a cada ciclo, cerca de 2,5% dos indivíduos com gengivite irão progredir para periodontite, mesmo com tratamento. Estes fatores apontam mais uma vez para a importância de um diagnóstico precoce. Definições clínicas inconsistentes são também apontadas como um fator que contribui para a dificuldade do diagnóstico (Bishop, 2021).

Segundo a atual, e mais recente, Classificação das Doenças e Condições Periodontais e Peri-implantares, criada em 2017 pela Academia Americana de Periodontologia e pela Federação Europeia de Periodontologia, a DP pode ser classificada em diferentes formas com base nas suas características clínicas, etiologia e patogénese. As principais formas de DP incluem: condições e doenças gengivais, periodontite e outras condições que afetam o periodonto (Steffens and Marcantonio, 2018).

A gengivite é a forma mais leve e reversível da DP, e é caracterizada pela inflamação da gengiva sem perda de inserção, manifestando-se frequentemente através de edema, sensibilidade aumentada, vermelhidão e sangramento fácil (pela escovagem ou alimentação, por exemplo) (European Federation of Periodontology, 2021). Esta condição caracteriza-se por poder afetar grande parte das pessoas em algum momento das suas vidas, no entanto, medidas simples como a execução de uma boa higiene oral e realização de consultas odontológicas de seguimento podem prevenir o seu aparecimento ou reverter, em alguns casos, a instalação da mesma (Centers for Disease Control and Prevention, 2024). A gengiva clinicamente saudável é um indicador prognóstico da longevidade dentária. Um estudo longitudinal demonstrou que os dentes com gengiva consistentemente saudável apresentaram uma taxa de sobrevivência dentária cumulativa de 99,5% aos 51 anos (Lang et al., 2009).

Por outro lado, o não tratamento desta condição pode levar ao aparecimento de periodontite (Centers for Disease Control and Prevention, 2024), ou seja, a gengivite é considerada a condição precursora da periodontite. Um estudo que analisou a progressão da gengivite para periodontite num grupo de homens noruegueses ao longo de 26 anos mostrou que a periodontite se desenvolveu apenas em áreas com gengivite de longa data. Ou seja, a presença de gengivite persistente aumenta significativamente o risco de desenvolver periodontite, reforçando assim o peso da prevenção e tratamento precoce da gengivite (Lang et al., 2009).

A Figura 1, adaptada de *"The periodontal pathway of care"* (Bishop, 2021) para português, ilustra de forma clara a importância da prevenção da abordagem à periodontite, realçando dois pontos de intervenção cruciais: intervenção de prevenção e intervenção de gestão.

A primeira ocorre na fase de gengivite e visa evitar a progressão desta condição que é reversível. A segunda ocorre após o diagnóstico de periodontite e visa estabilizar a doença e preservar os dentes. O diagrama mostra-nos que o caminho para a prevenção e tratamento deve ser ao longo da vida, centrado no paciente e composto por etapas incrementais. A primeira etapa do tratamento é focada no diagnóstico e informação, ou seja, o paciente é informado sobre o diagnóstico e sobre as opções de tratamento, bem

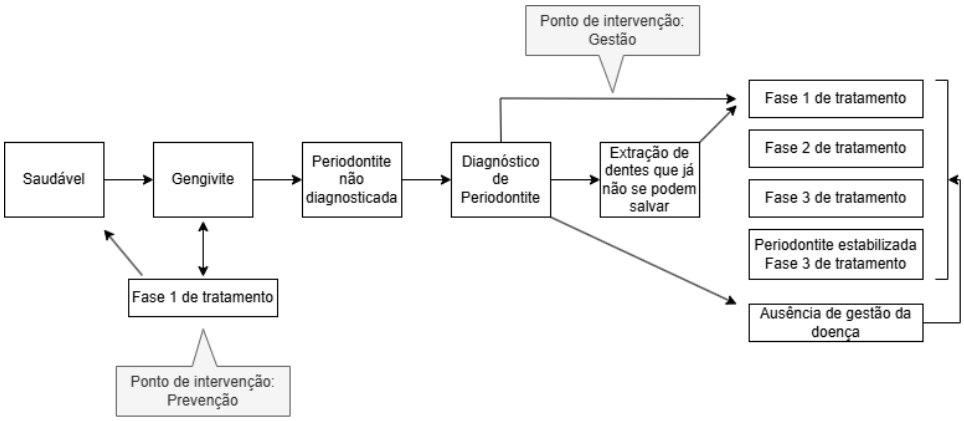

Figura 1: O caminho do Cuidado periodontal (adaptado de Bishop (2021)).

como é dado suporte para mudanças comportamentais e controlo de fatores de risco. A segunda etapa concentra-se em abordar as causas da doença, controlando e reduzindo a acumulação de placa bacteriana e tártaro, sendo que a cirurgia pode ser a etapa seguinte caso os objetivos de tratamento da segunda etapa não sejam conseguidos. Por último, após o tratamento ser bem-sucedido, é importante manter a estabilidade periodontal através de métodos terapêuticos e preventivos, uma vez que a periodontite é uma condição crónica.

A periodontite é sempre precedida por gengivite, sendo uma forma mais grave de DP, caracterizada pela perda progressiva das estruturas de suporte dos dentes, levando à formação de bolsas periodontais, recessão gengival e, eventualmente, perda de dentes (Papapanou et al., 2018). Ou seja, a periodontite é uma progressão da gengivite não tratada, onde a inflamação se estende dos tecidos gengivais para os tecidos de suporte dos dentes, podendo-se manifestar através de edema, vermelhidão, sensibilidade aumentada, aumento do sangramento (nesta fase pode até mesmo ser espontâneo), mau hálito persistente, mobilidade dentária e exposição das raízes dos dentes (Centers for Disease Control and Prevention, 2024) (Marotz et al., 2022). A palavra "periodontite" vem de "*periodontium*", que significa "ao redor do dente". Ou seja, o periodonto engloba todos os componentes que sustentam o dente no maxilar: o cemento, o ligamento periodontal, a gengiva e o osso alveolar. Num dente saudável, o periodonto envolve toda a raiz do dente (European Federation of Periodontology, 2021).

Atualmente, a periodontite é classificada através de um sistema multidimensional que inclui estadiamento e grau. O estadiamento diz respeito à severidade e extensão atual da doença (Tabela 1), orientando o plano de tratamento, e o grau diz respeito à progressão da doença (Tabela 2), determinando a resposta ao tratamento *standard* (Ertaş et al., 2022) (Papapanou et al., 2018). As características primárias da

periodontite incluem a perda de suporte dos tecidos periodontais, manifestada através da perda clínica de inserção, do inglês *CAL- Clinical Attachment Loss*, da perda óssea alveolar avaliada radiograficamente, do inglês *RBL- Radiografic Bone Loss*, da presença de bolsas periodontais e da hemorragia gengival (Papapanou et al., 2018). O estadio inicial da periodontite deve ser determinado primariamente através

Tabela 1: Classificação da periodontite com base em estadios definidos pela gravidade (de acordo com o nível de perda de inserção clínica interdentária, perda óssea radiográfica e perda dentária), complexidade, extensão e distribuição (adaptado de Papapanou et al. (2018)).

Estadio da periodontite		**Estadio I**	**Estadio II**	**Estadio III**	**Estadio IV**
Severidade	**CAL no local de maior perda**	1 a 2 mm	3 a 4 mm	≥5 mm	≥5 mm
	Perda óssea radiográfica	Terço coronário (<15%)	Terço coronário (15% a 33%)	Extensão até o terço médio da raiz e além	Extensão até o terço médio da raiz e além
	Perda de dentes	Nenhuma perda de dentes devido à periodontite	Nenhuma perda de dentes devido à periodontite	Perda de dentes devido à periodontite de ≤4 dentes	Perda de dentes devido à periodontite de ≥5 dentes
Complexidade	**Local**	Profundidade de sondagem máxima ≤4 mm Principalmente perda óssea horizontal	Profundidade de sondagem máxima ≤5 mm Principalmente perda óssea horizontal	Além da complexidade do estágio II: -Profundidade de sondagem ≥6 mm -Perda óssea vertical ≥3 mm -Envolvimento de furca classe II ou III -Defeito de crista moderado	Além da complexidade do estágio III: Necessidade de reabilitação complexa devido a: -Disfunção mastigatória -Trauma oclusal secundário (mobilidade dentária grau ≥2) - Defeito severo de crista -Colapso de mordida, migração, queimação -Menos de 20 dentes remanescentes (10 pares oponentes)
Extensão e distribuição	**Adicionar ao estadio como descritor**	Para cada estadio, descrever a extensão como localizada (<30% dos dentes envolvidos), generalizada, ou padrão molar/incisivo			

da CAL (característica determinante) e, se este dado não estiver disponível, deverá ser utilizada a RBL. Ainda assim, a perda de dentes devido à periodontite tem um peso decisivo na determinação do estadio. Outro fator contribuinte para a determinação do estadio é a complexidade, que se refere a fatores específicos que aumentam a dificuldade do tratamento, influenciam o prognóstico da doença e têm um impacto significativo na estética do paciente, nomeadamente a existência de lesões de furca ou mobilidades avançadas. Estes fatores são comummente designados de fatores que modificam o estadio. Para todos os estadios deve ainda ser associada a extensão, que pode ser localizada, generalizada ou padrão molar/incisivo (Papapanou et al., 2018) (Steffens and Marcantonio, 2018).

Tabela 2: Classificação da periodontite com base em graus que refletem as caraterísticas biológicas da doença, incluindo evidência de, ou risco de, progressão rápida, resposta antecipada ao tratamento e efeitos na saúde sistémica (adaptado de Papapanou et al.(2018)).

Grau de periodontite			**Grau A: Taxa de lenta progressão**	**Grau B: Taxa de moderada progressão**	**Grau C: Taxa de rápida progressão**
Critérios Primários	**Evidência direta de progressão**	**Dados longitudinais (RBL ou CAL)**	Evidência de nenhuma perda em 5 anos	<2 mm em 5 anos	≥2 mm em 5 anos
	Evidência indireta de progressão	**% perda óssea/idade**	<0.25	0.25 a 1.0	>1.0
		Fenótipo do caso	Grandes depósitos de biofilme, mas baixos níveis de destruição	Destruição proporcional aos depósitos de biofilme	A destruição excede o esperado para os depósitos de biofilme; padrões clínicos específicos sugestivos de períodos de progressão rápida e/ou doença de início precoce (por exemplo, padrão molar/incisivo; falta de resposta esperada às terapias padrão de controlo bacteriano).
Modificadores de Grau	**Fatores de Risco**	Tabagismo	Não Fumador	Fumador <10 cigarros/dia	Fumador ≥10 cigarros/dia
		Diabetes	Normoglicémico/ sem diagnóstico de diabetes	HbA1c <7.0% em pacientes com diabetes	HbA1c ≥7.0% em pacientes com diabetes

A determinação do grau é atribuída tendo em consideração o critério primário de classificação que engloba as evidências de progressão disponíveis, sendo que estas podem ser diretas ou indiretas. Para todos os doentes com periodontite deve ser assumido, numa primeira avaliação, o grau B, sendo que este deve ser ajustado ao critério primário, alterando-o para A ou C se houver evidência que o justifique. Quando existente, devem ser sempre utilizadas evidências de progressão diretas, calculadas ao longo dos anos, nomeadamente a CAL ou a RBL. Caso esses dados não se encontrem disponíveis, a evidência de progressão indireta é obtida através do cálculo da RBL em função da idade e das condições visíveis. Tal como acontece no estadiamento, também o grau pode ser alterado, neste caso pela presença de fatores de risco, nomeadamente tabagismo e se Diabetes *Mellitus* (DM) (Papapanou et al., 2018) (Steffens and

Marcantonio, 2018).

Fatores de Risco para doença periodontal

Numa fase inicial de desenvolvimento e descoberta das doenças periodontais, acreditava-se que todas as pessoas tinham a mesma probabilidade de desenvolver DP, e que a acumulação de placa bacteriana, uma má higiene oral e o trauma oclusal eram os únicos fatores que desencadeavam periodontite. Ou seja, a avaliação da pessoa com DP limitava-se à inspeção da cavidade oral com recurso a instrumentos odontológicos e análise radiográfica, assumindo que todas as pessoas tinham o mesmo risco. Com o crescente interesse científico nesta área que se demonstrou ser prioritária, tornou-se amplamente aceite que cada indivíduo tem uma suscetibilidade diferente para o desenvolvimento de DP, nomeadamente devido à influência dos fatores de risco (Dyke and Dave, 2005). A avaliação dos fatores de risco para a DP, alguns deles também mencionados como modificadores de grau na classificação da periodontite, deve ser incorporada na avaliação da pessoa como um todo. Ou seja, uma visão holística de cada indivíduo deve acompanhar todo o processo de diagnóstico e tratamento da doença. A avaliação do risco é crucial desde o momento um, ajudando na compreensão da taxa de progressão da doença ao momento pós-tratamento, contribuindo para a determinação da frequência dos cuidados de suporte/gestão da doença (Farina et al., 2023). Um fator de risco é definido como uma variável bem conhecida que tem um efeito direto ao potenciar um processo de doença, e é categorizado na literatura como modificável e não modificável, de acordo com a possibilidade de cada indivíduo alterar a presença do mesmo, ou não, respetivamente (Darby, 2022). Para além disso, algumas variáveis podem ser identificadas como indicadores de risco, ou seja, podem acrescer risco ao processo de doença, no entanto, não há evidência suficiente para as considerar um fator de risco (Darby, 2022).

Dentro dos fatores de risco modificáveis podemos encontrar o tabagismo, a diabetes, a higiene oral deficitária, a nutrição e o stress psicossocial. Por outro lado, a idade e a hereditariedade são apontadas como fatores de risco não modificáveis. O estatuto socioeconómico tem vindo a ser identificado como um indicador de risco (Darby, 2022).

Tabagismo

O tabagismo é um fator de risco muito bem estabelecido na literatura e é identificado como um fator de risco *major*. Este facto está espelhado na atual classificação do grau de periodontite, isto é, o tabagismo e, nomeadamente, o número de cigarros por dia, modifica diretamente a determinação do grau

de periodontite. Vários mecanismos tornam esta variável um fator de risco para a DP, nomeadamente o comprometimento da resposta imunitária, a alteração da microbiota oral e a influência negativa na capacidade de cicatrização dos tecidos periodontais (Shabil et al., 2024) (Rashid et al., 2024).

Um estudo transversal que teve como objetivo avaliar o estado periodontal em pessoas portadoras de diabetes insulinodependente e em pessoas não portadoras de diabetes, concluiu que o tabagismo foi significativamente associado a uma maior prevalência e gravidade da periodontite em ambos os grupos, mostrando o peso significativo deste fator de risco por si só (Haber et al., 1993). O estudo de BinShabaib et al. (2019) sobre a saúde periodontal em fumadores e não fumadores demonstrou que os fumadores de cigarros tradicionais apresentaram índices de placa mais elevados, assim como maior profundidade de sondagem e perda de inserção clínica em comparação com os não fumadores. Para além disso, os fumadores de cigarros tradicionais tinham maiores concentrações de Interleucina (IL)1β, IL-6, interferão γ (IFN-γ), fator de necrose tumoral α, em inglês *Tumor Necrosis Factor* α (TNF-α) e Matriz Metaloproteinase-8 (MMP-8) no fluído crevicular gengival em comparação com os não fumadores, corroborando a hipótese de que o tabagismo contribui para o aumento da inflamação periodontal. Desde o seu surgimento, os cigarros eletrónicos têm vindo a ganhar popularidade entre as pessoas fumadoras devido à ideia gerada de que seriam menos nocivos para a saúde, e, portanto, uma alternativa segura aos cigarros tradicionais. No entanto, vários estudos apontam para os efeitos negativos na saúde oral em geral. Um estudo transversal que teve como objetivo analisar a associação entre o uso de cigarros eletrónicos e a saúde oral concluiu que os utilizadores regulares destes dispositivos tinham mais probabilidades de sofrer perda óssea dentária do que os não utilizadores e, para além disso, a possibilidade de vir a ter perda óssea foi de quase 13 vezes maior para os utilizadores regulares (Mohajeri et al., 2024). Um outro estudo que pretendeu determinar o estado periodontal, o pH salivar e os níveis de cotinina em fumadores de cigarros tradicionais, fumadores de cigarros eletrónicos e não fumadores, concluiu que os fumadores no geral tinham parâmetros periodontais clínicos significativamente piores comparativamente aos não fumadores (Hasan et al., 2024). O estudo revelou ainda que os fumadores de cigarros eletrónicos apresentavam níveis semelhantes de cotinina aos dos fumadores de cigarros tradicionais, ou seja, sendo a cotinina o principal metabolito da nicotina, este achado alerta para a necessidade de monitorização dos níveis de nicotina nos cigarros eletrónicos e para os efeitos que estes podem ter para a saúde em geral e em particular para a saúde oral (Hasan et al., 2024). Ainda que os efeitos do cigarro eletrónico na saúde oral possam não ser tão notados como os do cigarro tradicional, o impacto permanece negativo, não só na DP como na resposta ao tratamento que é menos favorável em comparação com os não fumadores (Shabil et al., 2024).

Os programas de cessação tabágica têm-se mostrado aliados importantes na melhoria da saúde periodontal e, nomeadamente, no tratamento da periodontite. Rashid et al. (2024) conduziram um estudo observacional com 200 fumadores com periodontite, divididos em dois grupos: um grupo recebeu intervenções abrangentes para a cessação tabágica, enquanto o grupo de controlo continuou a fumar sem qualquer intervenção. Após 6 meses, o grupo de intervenção, com uma taxa de cessação tabágica de 72%, exibiu uma redução significativa na profundidade de sondagem, no nível de inserção clínica e na inflamação gengival, enquanto o grupo de controlo não mostrou alterações significativas nesses parâmetros. Num estudo prospetivo longitudinal, Dixit et al. (2024) verificaram uma redução significativa do índice de placa de 2,02 para 0,8 no grupo submetido a um programa de cessação tabágica e uma diminuição da inflamação gengival em 75% dos participantes. Os resultados destes estudos reforçam a importância de integrar programas de cessação tabágica no tratamento da periodontite em fumadores, realçando, mais uma vez, o peso determinante que o tabagismo tem na saúde periodontal.

Diabetes Mellitus

Segundo a Federação Internacional de Diabetes (2024), esta condição caracteriza-se por ser crónica e ocorre quando o pâncreas não consegue produzir insulina, ou quando o organismo não consegue utilizar a insulina que produz. Em 2021, em todo o mundo, aproximadamente 537 milhões de pessoas entre os 20 e os 79 anos tinham DM e estima-se que até 2030 esse valor aumente para os 643 milhões. Os fatores precipitantes desta condição estão perfeitamente definidos, e, ao mesmo tempo, ser portador de diabetes constitui um fator de risco para o desenvolvimento de outras doenças. As principais complicações afetam o coração, os vasos sanguíneos, os olhos, os rins, o sistema nervoso, os dentes e as gengivas (Federação Internacional de Diabetes, 2024).

A associação bidirecional entre DM e periodontite está bem estabelecida na literatura, estando a periodontite relacionada com um agravamento da resistência à insulina e, por sua vez, um mau controlo glicémico pode agravar as patologias da cavidade oral (Kudiyirickal and Pappachan, 2024). Dicembrini et al. (2020) realizaram uma meta-análise para avaliar a prevalência e gravidade da DP em pacientes portadores de DM tipo 1 e os resultados mostram que os indivíduos portadores de DM tipo 1 têm um risco de 2,51 vezes maior de desenvolver periodontite do que os indivíduos não portadores. Para além disso, o mesmo estudo demonstrou que dentro dos indivíduos portadores de DM tipo 1, naqueles que apresentavam um bom controlo glicémico a profundidade da CAL foi menor do que nos indivíduos com DM tipo 1 e controlo glicémico inadequado. Um estudo retrospetivo conduzido num hospital de medicina

dentária em Chandigarh, revelou que, dos 725 doentes portadores de DM, cerca de 24,2% dos casos desenvolveram periodontite, cerca de 73,3% tinham gengivite e apenas 2,1% dos casos apresentavam um estado de saúde periodontal (Devi et al., 2024). A prevalência da gengivite nos indivíduos portadores de diabetes deve, assim, constituir-se um foco de atenção ao nível da gestão da gengivite, de forma a parar a progressão para periodontite.

Em indivíduos que recebem tratamento para a DP pode observar-se uma redução dos níveis de bactérias e antigénios circulantes, bem como dos níveis de citocinas e mediadores inflamatórios. Isto resulta numa redução do estado inflamatório sistémico, levando a uma melhoria no ciclo de sinalização de insulina e, por sua vez, numa redução da resistência à insulina (Preshaw and Bissett, 2019). Um estudo de coorte em larga escala conduzido na Coreia por Chang et al. (2020) examinou a relação entre indicadores de higiene oral e o risco de desenvolver DM. Os resultados revelaram uma associação significativa entre a frequência da escovagem dos dentes e a ocorrência de DM. Escovar os dentes frequentemente (≥3 vezes/dia) foi associado a um risco menor de desenvolver DM. Por outro lado, a presença de DP e um número elevado de dentes em falta (≥15) foram identificados como fatores de risco para diabetes inaugural. O Programa Nacional de Promoção da Saúde Oral 2021-2025 reforça esta relação entre DM e saúde oral, mencionando que "nas pessoas com patologias sistémicas como diabetes, insuficiência renal, entre outras, a xerostomia associada a polimedicação resulta também num agravamento de problemas orais devendo ser dispensada especial atenção à higiene oral" (Direção Geral da Saúde, 2021). Ou seja, a componente preventiva deve estar sempre presente, com foco particular em grupos de risco como as pessoas portadoras de DM. Os profissionais de saúde devem estar cientes da relação bidirecional entre DM e DP e fornecer cuidados integrados, no seio de uma equipa multidisciplinar, para otimizar os resultados de saúde oral e sistémica.

Mediadores Inflamatórios na Periodontite

A progressão da gengivite para periodontite marca a transição de uma reação de defesa crónica e bem-sucedida para um mecanismo imunopatológico destrutivo. Os mecanismos de destruição tecidual são categorizados em ação direta das bactérias, através da produção de enzimas proteolíticas que degradam os tecidos periodontais, como o colágeno, e dano indireto através da resposta do hospedeiro, que ao desencadear uma resposta imunitária exagerada resulta na libertação de citocinas pró-inflamatórias e enzimas destrutivas pelos neutrófilos e macrófagos (Hasan and Palmer, 2014).

A resposta imune inata representa a primeira linha de defesa contra o aumento da heterogeneidade de espécies presentes no biofilme no início da gengivite, e envolve mecanismos não específicos como o efeito da barreira epitelial, a atuação dos fatores de proteção contidos na saliva e o reconhecimento de substâncias como o lipopolissacarídeo das bactérias *Gram*-negativas por recetores de reconhecimento de padrões que são expressos pelos neutrófilos e macrófagos. Este conjunto de ações é importante não só para a defesa inicial do organismo, mas também para a ativação da resposta imune adaptativa (Hasan and Palmer, 2014).

A resposta imune adaptativa caracteriza-se por ser específica e pela memória imunológica. Ainda na resposta imune inata, as células imunes inatas atuam como células apresentadoras de antigénio, fazendo com que sejam libertadas citocinas que vão ativar as células T e B, levando a dois tipos de respostas: mediadas por células e respostas imunitárias humorais. Embora essenciais para a defesa do hospedeiro, se desreguladas, estas respostas podem ter um impacto negativo. As células T, enquanto cruciais para a eliminação das bactérias, podem também causar danos tecidulares através da libertação excessiva de citocinas pró-inflamatórias, como a Interleucina (IL) 1β, a IL-6, a IL-12 e o TNF-α. Estas citocinas amplificam a inflamação, contribuindo para a destruição do ligamento periodontal e do osso alveolar. Por outro lado, o processo inflamatório envolve também níveis elevados de IL-4, antagonista do recetor (AR) IL-1, IL-10 e proteína induzida (IP-10) que se apresentam como reguladoras da resposta inflamatória (Ramadan et al., 2020) (Hasan and Palmer, 2014).

Relvas et al. (2024), avaliaram o potencial de várias citocinas salivares como biomarcadores da gravidade da periodontite. Os autores descobriram que níveis elevados de IL-6 e IL-1β estavam associados à periodontite grave (estadio III/IV), enquanto níveis mais baixos de IL-23 e IP-10 estavam associados a maior gravidade da doença. A proporção IL-1β/IL-1AR também aumentou em indivíduos com periodontite, sugerindo um desequilíbrio na resposta inflamatória.

Um outro estudo, conduzido por Majeed et al. (2022), investigou a associação entre os níveis de IL-1β na saliva e a gravidade da periodontite. Os indivíduos com periodontite foram divididos em três subgrupos: periodontite inicial, moderada e grave. Os níveis de IL-1β na saliva foram significativamente mais elevados em indivíduos com periodontite em comparação com indivíduos saudáveis. Para além disso, quanto maior a gravidade da doença, mais elevados eram os níveis de IL-1β. Os resultados também mostraram uma correlação positiva e significativa entre os níveis salivares de IL-1β e os parâmetros periodontais clínicos (índice de placa, sangramento à sondagem, profundidade de sondagem, perda de inserção clínica).

O estudo realizado por Cebesoy et al. (2024) demonstrou a importância da IL-18 na periodontite. Os investigadores descobriram que os níveis de IL-18 no fluido crevicular gengival eram significativamente mais elevados em indivíduos com periodontite avançada em comparação com indivíduos saudáveis. Para além disso, os níveis de IL-10 também demonstraram estar significativamente mais elevados em indivíduos com periodontite avançada. Sendo a IL-10 conhecida pelo seu papel anti-inflamatório, o facto de estar muito aumentada alerta para o mecanismo compensatório que esta citocina pode desempenhar na periodontite, tentando suprimir a produção descontrolada das citocinas pró-inflamatórias que acabam por ser prejudiciais.

A simples recolha de uma amostra de saliva de um indivíduo com DP parece ser um procedimento inócuo para o mesmo e pode efetivamente trazer grandes contributos no que diz respeito à análise dos mediadores inflamatórios como marcadores da doença. Os estudos mais recentes têm vindo a comprovar o potencial da incorporação destes dados no processo de diagnóstico, juntamente com os parâmetros clínicos já definidos pela classificação atual.

Algoritmos de Machine Learning

A Inteligência Artificial (IA) refere-se à capacidade de um computador ou uma máquina controlada por um computador de realizar tarefas associadas a processos intelectuais caraterísticos dos humanos (Copeland, 2024). Uma definição amplamente aceite descreve IA como "a ciência e a engenharia que consiste em criar máquinas inteligentes, especialmente programas de computador inteligentes. Está relacionada com a tarefa semelhante de utilizar os computadores para compreender a inteligência humana, mas a IA não tem de se limitar a métodos que sejam biologicamente observáveis" (McCarthy, sd), ou seja, a IA pode utilizar abordagens e técnicas diferentes daquelas que os seres humanos usam para pensar e aprender.

A Inteligência Artificial (IA) refere-se à capacidade de um computador ou uma máquina controlada por um computador de realizar tarefas associadas a processos intelectuais caraterísticos dos humanos. (Copeland, 2024) Uma definição amplamente aceite descreve IA como "a ciência e a engenharia que consiste em criar máquinas inteligentes, especialmente programas de computador inteligentes. Está relacionada com a tarefa semelhante de utilizar os computadores para compreender a inteligência humana, mas a IA não tem de se limitar a métodos que sejam biologicamente observáveis" (McCarthy, sd), ou seja, a IA pode utilizar abordagens e técnicas diferentes daquelas que os seres humanos usam para pensar e

aprender.

O conceito de IA é abrangente e engloba outros conceitos como ML e *Deep Learning*, sendo que ML é um ramo da IA e representa um processo complexo que permite que os algoritmos aprendam através dos dados de *input*, tornando possível fazer previsões sobre dados nunca vistos. Ou seja, ML é uma técnica baseada em IA que descobre relações entre os dados com o objetivo de descobrir padrões e tendências. Este processo vai desde o treino dos algoritmos com dados históricos até à conceção do modelo que irá ser usado para fazer previsões sobre dados nunca vistos (Figura 2).

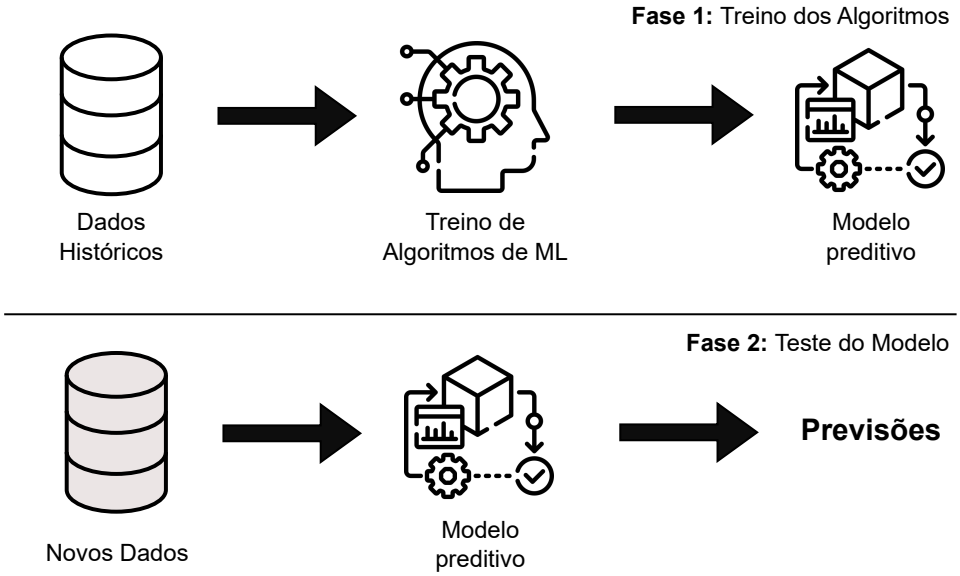

Figura 2: Estrutura geral da criação de um modelo preditivo baseado em ML, considerando a fase de treino e de teste (adaptado de Sarker (2021)).

Os algoritmos de ML podem ser amplamente categorizados em quatro tipos principais: aprendizagem supervisionada, não supervisionada, semi-supervisionada e por reforço (Chen, 2024) (Sarker, 2021). Cada categoria possui princípios distintos e adequa-se a diferentes tipos de problemas e dados.

A aprendizagem supervisionada é um método dominante no campo da mineração de dados, onde um modelo é desenvolvido através da aprendizagem de um conjunto de dados com rótulos conhecidos, permitindo assim prever o resultado de exemplos não rotulados. Esta abordagem é frequentemente utilizada para problemas de classificação (onde a variável de saída é discreta, como por exemplo "doente"ou "saudável ") e regressão (onde a variável de saída é um valor real e contínuo, como por exemplo o risco de desenvolver uma doença cardiovascular) (Sarker, 2021). Na área biomédica, a aprendizagem supervisio-

nada é amplamente aplicada no diagnóstico de doenças e na identificação de fatores de risco, treinando algoritmos com dados rotulados (por exemplo, informações demográficas, sintomas, histórico médico, biomarcadores e os rótulos correspondentes da doença) para identificar padrões e fazer previsões precisas sobre a doença em novos pacientes (Binson et al., 2024).

Ao contrário da aprendizagem supervisionada, a aprendizagem não supervisionada analisa conjuntos de dados sem rótulos ou resultados predefinidos. Este método é utilizado para descobrir padrões, tendências, agrupamentos e estruturas significativas em dados, bem como para fins exploratórios. As tarefas comuns de aprendizagem não supervisionada incluem *clustering* (agrupamento de pontos de dados semelhantes em *clusters*), redução de dimensionalidade (simplificação de modelos, redução de custos computacionais e prevenção de *overfitting*), entre outros. Estas técnicas são particularmente úteis na pesquisa biomédica para identificar subtipos de doenças, agrupar pacientes com base em características semelhantes e detetar anomalias (Sarker, 2021) (Binson et al., 2024).

A aprendizagem semi-supervisionada surge como uma hibridização dos métodos supervisionados e não supervisionados, operando tanto com dados rotulados quanto não rotulados. Esta abordagem é útil em cenários do mundo real onde os dados rotulados são escassos, mas os dados não rotulados são abundantes, visando proporcionar resultados de previsão superiores aos obtidos apenas com dados rotulados (Sarker, 2021) (Binson et al., 2024).

Por último, a aprendizagem por reforço é um tipo de algoritmo que permite aos agentes de *software* e máquinas avaliar automaticamente o comportamento ideal num contexto ou ambiente específico para melhorar a sua eficiência. É uma abordagem impulsionada pelo ambiente, baseada em recompensas ou penalidades, e tem como objetivo maximizar a recompensa ou minimizar o risco através de *insights* obtidos da interação ambiental (Binson et al., 2024) (Sarker, 2021).

No contexto biomédico, o aumento exponencial na quantidade e complexidade dos dados de saúde (como registos de saúde eletrónicos e dados administrativos) tem direcionado uma atenção significativa para o uso apropriado de técnicas de ML na investigação. No entanto, a seleção do algoritmo apropriado é um desafio, uma vez que o propósito e o desempenho de diferentes algoritmos podem variar significativamente dependendo das características dos dados e do objetivo da aplicação. Além disso, a qualidade dos dados, a interpretabilidade do modelo e as considerações éticas são desafios importantes que precisam de ser abordados. Entre os algoritmos de aprendizagem supervisionada mais utilizados destacam-se

Naive Bayes, *K-Nearest Neighbors*, *Decision Trees*, *Random Forest*, *Support Vector Machine* e *Regressão Logística*, cada um apresentando princípios de funcionamento, vantagens e limitações específicos, bem como desempenhos diferenciados em aplicações biomédicas.

Naive Bayes

O algoritmo *Naive Bayes* é uma técnica de classificação probabilística fundamentada no Teorema de *Bayes* que calcula a probabilidade de um evento acontecer com base num conhecimento *à priori*. Assume que as variáveis de entrada são independentes entre si, simplificação que, embora muitas vezes irrealista, permite elevada eficiência e baixo custo computacional. Trata-se de um modelo particularmente adequado para grandes bases de dados, requerendo uma quantidade reduzida de instâncias de treino e permitindo a realização de classificações binárias e multiclasse. A sua simplicidade, no entanto, é também uma limitação: a suposição de independência entre atributos pode comprometer a precisão em domínios onde existe forte correlação entre as variáveis, e a sensibilidade a *outliers* também afeta o seu desempenho (Uddin et al., 2019) (Sarker, 2021) (Binson et al., 2024).

K-Nearest Neighbors

O algoritmo *K-Nearest Neighbors* representa uma abordagem não paramétrica baseada em instâncias, em que a classificação de um novo exemplo é determinada pela proximidade em relação aos exemplos armazenados no conjunto de treino (Figura 3). Utiliza métricas de distância, como a euclidiana, e atribui a classe mais frequente entre os *k* vizinhos mais próximos. (Uddin et al., 2019) (Sarker, 2021) (Binson et al., 2024).

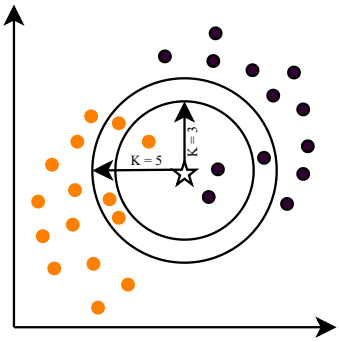

Figura 3: Ilustração simplificada do algoritmo K-Nearest Neighbors. Quando K=3, o objeto de amostra (estrela) é classificado como preta, uma vez que obtém mais votos da classe preta. No entanto, para K = 5, o mesmo objeto de amostra é classificado como vermelha, uma vez que agora obtém mais votos da classe vermelha.(adaptado de Uddin et al. (2019)).

Este algoritmo é apreciado pela sua simplicidade e pela capacidade de lidar com relações complexas e não lineares, além de apresentar robustez perante ruídos ao considerar múltiplos vizinhos em vez de instâncias isoladas. Contudo, é computacionalmente dispendioso para grandes conjuntos de dados, sensível à escala das variáveis, e exige a escolha criteriosa do número ótimo de vizinhos.

Decision Trees

Decision Trees são modelos intuitivos e de fácil interpretação, que representam lógicas de decisão por meio de uma estrutura hierárquica em formato de árvore, onde os nós internos correspondem a testes sobre atributos e os nós folha representam as classes finais (Figura 4). A sua maior vantagem reside na transparência do processo de classificação, facilitando a interpretação clínica e tornando o modelo útil em contextos biomédicos que exigem explicabilidade. Este algoritmo é capaz de lidar com diferentes tipos de dados e permite identificar relações relevantes entre variáveis. Contudo, apresenta algumas limitações, como a instabilidade do modelo perante pequenas alterações nos dados, a tendência ao *overfitting* em árvores muito profundas e a dependência da ordem das variáveis para o processo de divisão. Os critérios mais utilizados na divisão das variáveis são o Índice de *Gini* e a Entropia, sendo que o primeiro mede a probabilidade de um elemento ser classificado incorretamente se fosse atribuído aleatoriamente de acordo com a distribuição de classes num nó, e o segundo mede o grau de incerteza na distribuição de classes num nó (Uddin et al., 2019) (Sarker, 2021) (Binson et al., 2024).

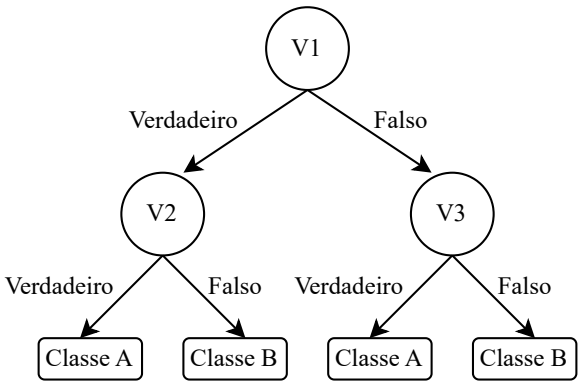

Figura 4: Ilustração de uma *Decision Tree*. Cada variável (V1, V2 e V3) é representada por um círculo e os resultados das decisões (Classe A e Classe B) correspondem aos retângulos. Para classificar uma amostra numa classe, cada ramo é rotulado como "Verdadeiro" ou "Falso" com base no valor do resultado do teste do seu nó ancestral. (Adaptado de Uddin et al. (2019)).

Random Forest

O *Random Forest* surgiu como uma extensão do algoritmo *Decision Trees*, utilizando um conjunto de múltiplas árvores para reduzir a variância e aumentar a precisão do modelo. Trata-se de uma técnica de *ensemble learning*, em que cada árvore é treinada sobre subconjuntos aleatórios dos dados, e a classificação final resulta da votação da maioria (para variáveis discretas) ou da média (para variáveis contínuas). Portanto, o modelo de aprendizagem *Random Forest*, com múltiplas árvores de decisão, é normalmente mais preciso do que um modelo baseado numa única árvore de decisão. Este método apresenta como vantagens a elevada robustez, a menor propensão ao *overfitting*, a boa escalabilidade para grandes volumes de dados e a possibilidade de estimar a importância relativa das variáveis. Por outro lado, é mais complexo, exige maior capacidade computacional e pode favorecer atributos com muitos valores distintos (Uddin et al., 2019) (Sarker, 2021) (Binson et al., 2024).

Support Vector Machine

O modelo *Support Vector Machine* constitui um dos métodos mais robustos para problemas de classificação linear e não linear. O seu funcionamento baseia-se no mapeamento dos dados para um espaço de maior dimensão, no qual se procura identificar um hiperplano ótimo capaz de separar as classes, maximizando a margem entre elas e reduzindo os erros de classificação. Entre as suas principais vantagens destacam-se a elevada robustez, o baixo risco de *overfitting* e a capacidade de lidar com dados não estruturados ou semiestruturados, como textos e imagens. Além disso, a utilização de diferentes funções *kernel* permite uma adaptação flexível a vários tipos de problemas. No entanto, o *Support Vector Machine* apresenta desvantagens relevantes, sendo computacionalmente exigente para grandes volumes de dados, sensível ao ruído e dependente de um pré-processamento adequado, nomeadamente na normalização. A interpretação dos modelos é frequentemente complexa e, na sua forma básica, a técnica limita-se a problemas de classificação binária (Uddin et al., 2019) (Sarker, 2021) (Binson et al., 2024).

Regressão Logística

A Regressão Logística constitui um dos modelos mais clássicos de classificação, amplamente utilizada em epidemiologia e estatística médica (Schober and Vetter, 2021). Baseia-se na função logística (ou sigmoide), dada pela Equação 2.1, para estimar a probabilidade de ocorrência de um evento dicotómico $Y = 1$, em função de um conjunto de variáveis $X_1, X_2, \ldots, X_p$.

$$f(X) = P(Y = 1 \mid X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p)}} \tag{2.1}$$

onde $P(Y = 1|X)$ representa a probabilidade de ocorrência do evento e β_i os coeficientes do modelo.

Em epidemiologia e estatística médica, é comum interpretar os coeficientes em termos de *odds* e *Odds Ratio* (OR) (Schober and Vetter, 2021).

- *Odds* representam a razão entre a probabilidade de ocorrência do evento e a probabilidade de não ocorrência:

$$\text{Odds} = \frac{P}{1 - P}$$

- O OR é obtido exponenciando o coeficiente β_i:

$$\text{OR}_i = e^{\beta_i}$$

  OR indica quantas vezes as *odds* de ocorrência do evento se multiplicam quando a variável X_i aumenta uma unidade, mantendo todas as outras constantes.

Desta forma:

- Se $OR > 1$, o aumento da variável está associado a maiores *odds* do evento (maior risco relativo).
- Se $OR < 1$, o aumento da variável está associado a menores *odds* do evento (menor risco relativo).
- O intercepto β_0 ajusta a escala global do modelo e representa as *odds* de base quando todas as variáveis independentes são zero.

Esta interpretação permite traduzir os resultados do modelo de forma clínica: cada coeficiente indica o impacto relativo de uma variável na probabilidade de ocorrência da doença, fornecendo informação quantitativa útil para profissionais de saúde na avaliação de risco individual. É um modelo flexível, que não exige suposições rigorosas sobre a distribuição das variáveis independentes. No entanto, a Regressão Logística apresenta limitações quando aplicada a dados com relações não lineares complexas, sendo sensível a *outliers* e, na sua versão básica, restrita a problemas de classificação binária. Além disso, a sua dependência da relação linear entre variáveis pode reduzir o desempenho em bases biomédicas mais complexas (Uddin et al., 2019) (Sarker, 2021) (Binson et al., 2024).

De forma global, observa-se que cada algoritmo de ML apresenta vantagens e limitações distintas que devem ser cuidadosamente ponderadas em função do problema em estudo. Métodos mais clássicos, como a Regressão Logística, destacam-se pela simplicidade, rapidez e interpretabilidade, características que favorecem a sua aceitação em contextos clínicos onde a explicabilidade dos resultados é essencial. No entanto, estas abordagens tendem a falhar perante relações complexas ou não lineares entre variáveis, comuns em dados biomédicos de grande escala. Por outro lado, algoritmos mais sofisticados, como *Support Vector Machine* e *Random Forest*, apresentam maior capacidade preditiva e robustez, sobretudo em conjuntos de dados de alta dimensão, embora frequentemente à custa de maior complexidade computacional e menor transparência na interpretação dos resultados. Já métodos como o *Naive Bayes* e o *K-Nearest Neighbors* oferecem soluções intermédias: o primeiro caracteriza-se pela elevada eficiência computacional, mas sofre com a suposição simplificadora da independência entre variáveis; o segundo, apesar da flexibilidade em capturar padrões não lineares, torna-se computacionalmente dispendioso em bases de dados extensas. As *Decision Trees*, por sua vez, conciliam interpretabilidade com razoável desempenho, mas revelam instabilidade quando sujeitas a pequenas variações nos dados. Assim, a escolha do algoritmo mais adequado não se deve basear apenas na precisão que oferece, mas também na interpretabilidade, na robustez face ao ruído, na escalabilidade e, sobretudo, na viabilidade de aplicação clínica. Esta visão crítica evidencia que não existe um modelo superior a outro, mas sim diferentes ferramentas a serem utilizadas de forma estratégica, consoante os objetivos da investigação e as características específicas dos dados biomédicos analisados.

Na Tabela 3 encontram-se resumidas algumas vantagens e desvantagens dos algoritmos mencionados.

Tabela 3: Resumo das vantagens e desvantagens dos algoritmos de ML.

Algoritmo	**Vantagens**	**Desvantagens**
Regressão Logística	Simplicidade; Rapidez; Alta interpretabilidade; Boa aceitação em contextos clínicos	Dificuldade em lidar com relações complexas ou não lineares; Limitações com dados biomédicos de grande escala
Support Vector Machine (SVM)	Maior capacidade preditiva; Robusto em dados de alta dimensão	Maior complexidade computacional; Menor transparência/interpretabilidade
Random Forest	Alta capacidade preditiva; Robusto em dados de alta dimensão	Maior complexidade computacional; Menor interpretabilidade dos resultados
Naive Bayes	Elevada eficiência computacional	Suposição simplificadora de independência entre variáveis pode reduzir a precisão
K-Nearest Neighbors (KNN)	Flexível para capturar padrões não lineares	Computacionalmente dispendioso em bases de dados extensas
Decision Trees	Boa interpretabilidade; Razoável desempenho	Instabilidade com pequenas variações nos dados (alta variância)

Machine Learning e previsão da Doença Periodontal

A IA está a transformar rapidamente o setor da saúde, com aplicações que vão desde o diagnóstico e tratamento até à descoberta de medicamentos. A par disso, a IA tem vindo a ser destacada como uma arma para fazer frente a grandes desafios deste setor como a existência de uma mão de obra saturada que enfrenta cada vez mais a problemática do *burnout* (Almyranti et al., 2024) (Oracle, 2023). Em 2018, a conceituada revista americana *Forbes* destacou as cinco aplicações com maior potencial da IA na área da saúde, entre elas o suporte à decisão clínica (Marr, 2018). O ML surge como um aliado na medicina de precisão, quer ao nível da prevenção como do tratamento, ajudando os profissionais de saúde a personalizar os cuidados que prestam, com base na análise de grandes volumes de dados que incluem o perfil de doença de cada indivíduo, informações genéticas, dados demográficos, registos eletrónicos de

saúde, entre outros (Bohr and Memarzadeh, 2020).

Alguns estudos exploraram o uso de algoritmos de ML para classificar a DP, bem como identificar fatores de risco associados à presença da doença e à extensão da mesma. Em 2022, Ertaş et al., utilizaram diferentes algoritmos de ML para classificar a periodontite quanto ao estadio e quanto ao grau, com o objetivo de eleger o melhor modelo que pudesse ser utilizado para diagnosticar os doentes na prática clínica diária e facilitar a aplicação da nova classificação para as doenças periodontais especialmente para clínicos inexperientes. O estudo revelou uma precisão de 97,2% a 98,6% na classificação do estadio da periodontite com algoritmos como *Decision Tree*, *Random Forest* e *K-Nearest Neighbors*. Uma outra abordagem conduzida por Ozden et al. (2015) obteve uma precisão de 98% na classificação de doenças periodontais utilizando *Decision Tree* e *Suport Vector Machines*, reforçando o desenvolvimento de modelos de ML como uma ferramenta e não como um substituto ao julgamento e experiência clínicos. Em 2022, Alqahtani et al. identificaram a idade e as habilitações literárias como os preditores mais importantes para a presença e severidade da DP, destacando a coocorrência de fatores sociodemográficos e comportamentais como importantes para a identificação de pessoas vulneráveis ao desenvolvimento de DP. Deng et al. (2023) desenvolveram um modelo de ML capaz de classificar indivíduos em diferentes categorias, nomeadamente em saúde periodontal, gengivite e periodontite nos vários estadios (I, II, III e IV), utilizando parâmetros não clínicos e biomarcadores salivares. O modelo que utilizou o algoritmo RF demonstrou uma alta precisão, com um valor de *Area Under the Curve* (AUC) > 0,94, na discriminação das seis categorias. Os resultados revelaram o potencial desta abordagem para otimizar a gestão dos serviços de saúde periodontal, direcionando os indivíduos para o nível de cuidados adequado à sua condição.

Apesar dos resultados promissores, estes estudos revelam também algumas limitações que incluem o tamanho das amostras e o desbalanceamento dos dados entre os diferentes estadios, a utilização de dados retrospetivos e a falta de validação externa (Ertaş et al., 2022) (Ozden et al., 2015) (Alqahtani et al., 2022) (Deng et al., 2023). A garantia de reprodutibilidade e interpretabilidade dos modelos de ML no setor da saúde representa um desafio significativo nos dias de hoje, tornando-se imperativa a implementação de medidas que assegurem estas questões, sustentando a credibilidade e legitimidade do ML na medicina em geral (Ciobanu-Caraus et al., 2024).

Parte II

Metodologia, Resultados e Discussão

Capítulo 3

Metodologia

Esta secção descreve os procedimentos metodológicos utilizados no desenvolvimento do presente estudo, que teve como objetivo analisar os fatores de risco associados à DP, bem como a sua utilização na previsão da mesma.

Para garantir a reprodutibilidade dos resultados, foram fixadas sementes aleatórias (*random state*) em todos os procedimentos que envolvem aleatoriedade, tais como a divisão dos dados em treino e teste e a inicialização de alguns modelos de ML. Além disso, o estudo foi conduzido em ambiente controlado (*Python* 3.12.7, bibliotecas *Scikit-learn*, *Numpy*, *Pandas*, entre outras), assegurando que outros investigadores possam replicar os resultados obtidos. Toda a componente prática foi desenvolvida através da ferramenta *Jupyter Notebook* e pode ser acedida no meu repositório *GitHub* em: https://github.com/joana-lopes7/Analise-de-fatores-de-risco-e-previsao-da-doen-a-periodontal-com-recurso-a-Machine-Learning-.git.

3.1 Recolha de Dados

Este estudo analisou dados clínicos de 189 indivíduos na condição de ter ou não ter DP. Os dados foram recolhidos de acordo com o processo n°22/2022 da Comissão de Ética de Saúde do Centro Hospitalar do Tâmega e Sousa e registados numa base de dados Excel.

Esta base de dados contém registos de indivíduos adultos, entre os 19 e os 72 anos de idade, submetidos a exames clínicos periodontais, bem como informações recolhidas através de questionários, como por exemplo hábitos de higiene oral e consumo de tabaco. Para além disso, fizeram parte das variáveis em estudo os valores relativos à deteção de mediadores inflamatórios/citocinas. A recolha desses dados foi realizada através da utilização de *Kits* de quantificação recorrendo a amostras de saliva dos indivíduos em estudo, recolhidas de acordo com os protocolos éticos aprovados para o mesmo.

Nas amostras relativas a indivíduos não portadores de DM os níveis de citocinas na saliva foram quantificados em pg/mL utilizando o *kit LEGENDplex™ Human Macrophage/Microglia Panel (13-plex) (Cat. 740503, BioLegend, San Diego, CA, USA)*. Segundo o manual de instruções, este *kit* é baseado em citometria de fluxo que permite a deteção simultânea de 13 citocinas e quimiocinas humanas relevantes na resposta imune. O ensaio foi conduzido de acordo com o protocolo do fabricante, utilizando microesferas codificadas com fluorescência específicas para cada analito, permitindo uma análise multiplex sensível e quantitativa. A leitura foi realizada por citometria de fluxo e os dados foram analisados através do *software LEGENDplex™ Data Analysis Software Suite*. Para as citocinas incluídas neste estudo, o limite de deteção foi de 2,44 pg/mL (BioLegend, 2025).

Nas amostras relativas a indivíduos portadores de DM os níveis de citocinas na saliva foram também quantificados em pg/mL, tendo sido utilizado o *kit LEGENDplexTM Human Essential Immune Response Panel (13-plex) (ref. 740930, Biolegend, CA, USA)* que permite a quantificação simultânea de 13 analitos. O ensaio é baseado na tecnologia *Luminex® xMAP*, que utiliza microesferas magnetizadas com códigos fluorescentes distintos, permitindo uma análise *multiplex* de alta sensibilidade. O protocolo experimental seguiu as instruções do fabricante, incluindo etapas de incubação com anticorpos de captura e deteção, e leitura num sistema compatível com a tecnologia Luminex®. Os limites de deteção foram: 2,44 pg/mL para todas as citocinas, exceto IL-1β (2,69 pg/mL), MCP-1 (2,2 pg/mL), IL-17A (3,66 pg/mL), IL-6 (2,2 pg/mL), IL-8 (2,69 pg/mL) e TGF-β (5,37 pg/mL) (BioLegend, 2025).

3.2 Análise exploratória e pré-processamento de dados

Considerada um mantra em ML, a expressão "*Garbage in, garbage out*" refere-se à ideia de que a qualidade do *output* de um sistema depende diretamente da qualidade do *input* do mesmo (Zdrok, 2024). Ou seja, se os dados utilizados para o treino de um algoritmo de ML forem de baixa qualidade, o *output* previsto pelo mesmo não será confiável. Assim, o pré-processamento dos dados configurou-se como uma das etapas mais críticas no desenvolvimento dos modelos de ML. O *workflow* iniciou-se com a importação das bibliotecas necessárias à leitura e tratamento dos dados, e que são de uso aberto, tais como *Pandas*, *Numpy*, *Scikit-learn*, *Matplotlib* e *Seaborn*. As primeiras três deram resposta a tarefas como leitura dos dados, tratamento de valores duplicados ou valores ausentes e identificação de *outliers*. As duas últimas bibliotecas permitiram visualizar os dados, auxiliando na identificação de possíveis irregularidades, nomeadamente a presença de dados não balanceados, suportando uma análise descritiva e exploratória das *features* presentes.

O conjunto de dados analisado continha 189 amostras e 31 variáveis. A variável original "SAMPLE FLUID" correspondia ao identificador único de cada amostra, com um padrão que permitia distinguir entre utentes portadores e não portadores de DM: identificadores iniciados por "C" representavam utentes não portadores de DM, enquanto os iniciados por "SD" correspondiam a utentes portadores de DM. Para permitir a utilização desta informação (ter ou não ter DM) como variável preditiva, dado o seu papel como fator de risco para a DP, foi criada a coluna binária "Diabetes", onde 0 representava os utentes não portadores da doença e 1 representava os utentes com diagnóstico de DM. Esta variável categórica revelou uma distribuição equilibrada, com 95 amostras da categoria 0 e 94 amostras da categoria 1. Após este processamento, os identificadores originais foram anonimizados e renomeados com um prefixo "A" seguido de um número sem significado ordinal, e a coluna passou a designar-se simplesmente por "ID".

Variáveis numéricas como "PI_total_percentage" (percentagem de placa bacteriana total), "BOP_total_percentage" (percentagem de sangramento à sondagem total), "PPD_total" (profundidade de bolsa à sondagem total), "CAL_total" (perda de inserção clínica total, em milímetros), "No.teeth" (número de dentes), "Age" (idade), "Cigarros_dia" (número de cigarros fumados por dia) e "Qtas vezes" (frequência diária de escovagem dentária) foram exploradas estatisticamente. A variável "Status_perio", que representa o estado periodontal dos utentes, foi recodificada para fins de modelação. Originalmente composta por três categorias (0 - Saúde, 1 – Gengivite, 2 - Periodontite), foi transformada numa variável binária que permitisse distinguir entre "Saúde Periodontal" (0) e "Doença Periodontal" (1), agregando as categorias de gengivite e periodontite, que, de acordo com a revisão de literatura, se constituem como condições de doença periodontal (Steffens and Marcantonio, 2018). Esta variável servirá como *target* para os modelos de classificação.

Variáveis com relevância apenas em contextos específicos de periodontite — como "Stage_New_classification", "Extensão" e "Grade" — foram excluídas da análise, dado o seu contributo limitado para a generalização do modelo. Isto é, estas variáveis apenas diziam respeito a indivíduos com um tipo específico de DP, a periodontite. As restantes variáveis categóricas foram revistas quanto à codificação. A maioria já se encontrava dicotomizada (por exemplo, "Sex", "Fumador_ativo", "Lavar_diariamente"), enquanto variáveis como "Escolaridade" mantiveram a sua codificação ordinal (valores de 0 a 6), considerando a sua estrutura hierárquica.

Por fim, assegurou-se que todas as variáveis relevantes estivessem devidamente formatadas para serem utilizadas nos modelos de ML, sem necessidade adicional de técnicas como *one-hot encoding*, dado

o formato já apropriado das variáveis categóricas.

3.3 Mediadores Inflamatórios

Após o pré-processamento geral dos dados, foi realizada uma análise estatística exploratória dos mediadores inflamatórios selecionados, com o objetivo de verificar a adequação dos mesmos para incorporação nos modelos de ML. Esta etapa incluiu a avaliação da distribuição dos dados, aplicação de transformações, testes de hipóteses e preparação final das variáveis.

3.3.1 Tratamento de valores "Below Detection Limit"

Na análise dos mediadores inflamatórios presentes na base de dados, identificou-se que várias variáveis continham uma quantidade significativa de valores classificados como *Below Detection Limit* (BDL), ou seja, concentrações abaixo do limite de deteção analítico (em inglês, *Limit of Detection* – LOD). Estes valores representam amostras com concentrações tão baixas que o equipamento ou método utilizado não consegue quantificá-las com precisão fiável.

A presença excessiva de valores BDL pode comprometer a qualidade dos dados e introduzir enviesamentos nas análises estatísticas, uma vez que indica ausência ou baixa fiabilidade na medição do biomarcador para essas amostras. Assim, estabeleceu-se um critério metodológico para a exclusão de mediadores inflamatórios que apresentassem mais de 30% de valores BDL, em linha com as recomendações da literatura especializada em epidemiologia e biomarcadores clínicos (Polinski et al., 2021). O limiar de 30% foi adotado com o objetivo de garantir a robustez estatística e a validade inferencial dos modelos, dado que variáveis com excesso de valores ausentes ou não detetáveis podem aumentar a incerteza e reduzir o poder das análises. Após a aplicação deste critério, os mediadores que permaneceram na base de dados e que ainda continham valores BDL foram sujeitos a imputação.

Uma das estratégias para tratamento de valores BDL consiste em substituir os valores BDL pelo limite de deteção fornecido pelo fabricante do *kit* utilizado (Li et al., 2024). Neste caso, seguindo essa mesma linha, recorreu-se à estratégia de substituição dos valores BDL pelo valor correspondente a metade do limite de deteção (LOD/2), uma abordagem conservadora e amplamente utilizada em estudos ambientais e biomédicos (Manzardo et al., 2016) (Ashwood et al., 2011). Esta técnica permite preservar as observações sem inflacionar as estimativas médias, minimizando o enviesamento causado pela ausência de deteção. Os limites de deteção variaram consoante o grupo experimental e o *kit* utilizado para a

quantificação, tal como referido no início deste capítulo. Esta estratégia permitiu manter o maior número possível de amostras nas análises estatísticas subsequentes, aumentando a representatividade dos dados e garantindo maior fiabilidade dos resultados, sem comprometer a validade dos resultados.

3.3.2 Teste de normalidade

Inicialmente, procedeu-se à avaliação da normalidade dos dados referentes aos mediadores inflamatórios filtrados (IP-10, IL-1β, MCP-1, IL-6 e IL-8), através do teste de *Shapiro-Wilk*, apropriado para amostras com dimensão moderada. Os resultados obtidos revelaram que todas as variáveis apresentavam distribuições significativamente diferentes da normal ($p < 0{,}05$), evidenciando forte assimetria à direita. Esta característica é comum em biomarcadores inflamatórios e pode comprometer a aplicação direta de métodos estatísticos paramétricos ou algoritmos de ML sensíveis à escala dos dados.

3.3.3 Transformação logarítmica

Para mitigar a assimetria e reduzir o impacto de *outliers*, foi aplicada a transformação logarítmica natural acrescida de 1 (*log1p*), amplamente recomendada para variáveis contínuas com distribuição assimétrica. Esta técnica tem como objetivo comprimir a escala dos valores mais elevados e estabilizar a variância, contribuindo para uma estrutura de dados mais adequada à modelação preditiva.

3.4 Preparação do dataset para o treino dos algoritmos de ML

Concluída a fase de transformação e imputação dos dados, procedeu-se à criação do conjunto de dados final a utilizar nos modelos de ML. Esta etapa consistiu na remoção de colunas redundantes, derivadas de transformações intermediárias, e de variáveis com elevado número de valores omissos ou relevância clínica restrita. Foram eliminadas as versões originais dos mediadores inflamatórios, mantendo-se apenas as respetivas variáveis mais adequadas para modelação preditiva.

Da mesma forma, as variáveis “Stage_New_Classification”, “Extensión” e “Grade” foram excluídas, uma vez que apresentavam utilidade limitada fora do contexto específico de estadiamento clínico da periodontite, não contribuindo para a generalização do modelo. O *dataset* final incluiu todas as variáveis consideradas relevantes e devidamente preparadas, entre elas, variáveis clínicas, comportamentais, sociodemográficas e moleculares, todas em formato numérico e compatíveis com os requisitos dos algoritmos de ML. A variável ”Status perio”, previamente recodificada de forma binária (0 = saúde periodontal; 1 =

doença periodontal), foi mantida como variável alvo para os modelos de classificação a serem desenvolvidos.

A Figura 5 ilustra o fluxo de pré-processamento aplicado ao conjunto de dados, desde o *dataset* original que continha 31 variáveis, até à construção do *dataset* final com 21 variáveis devidamente tratadas e preparadas para a aplicação de algoritmos de ML. Este *workflow* assegurou a consistência e a qualidade dos dados utilizados na modelação preditiva.

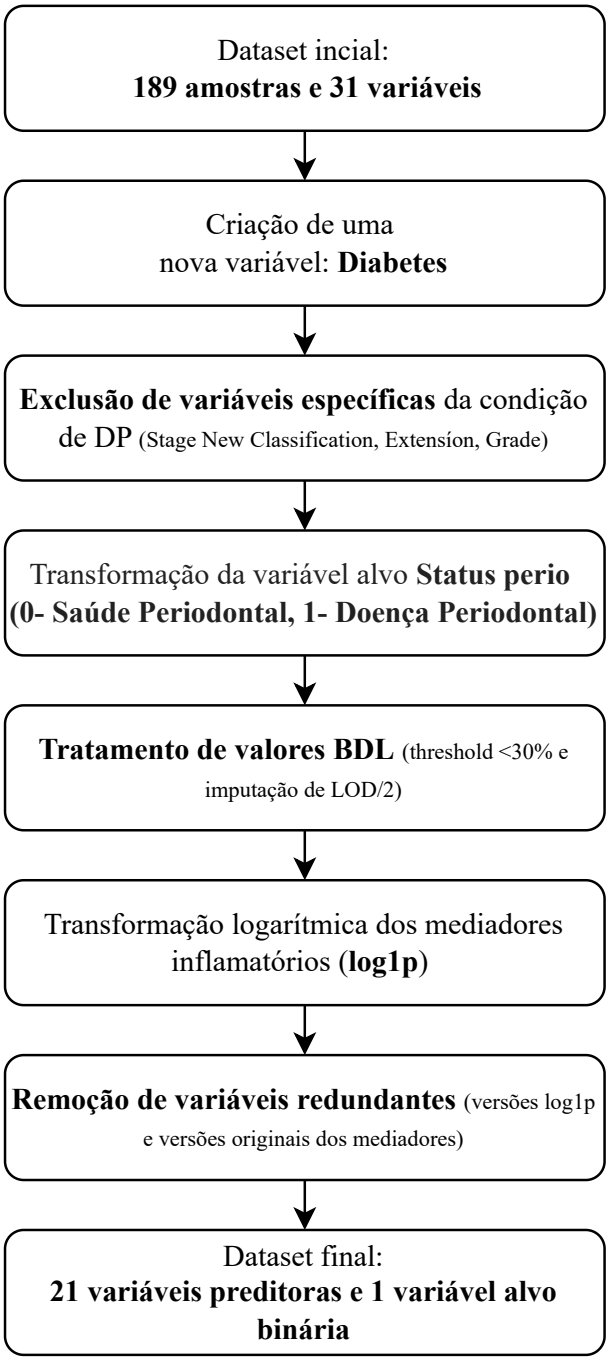

Figura 5: *Workflow* de pré-processamento dos dados.

3.4.1 Definição do dataset para ML e Método de Avaliação de Desempenho dos modelos

Após a preparação do conjunto de dados para o treino dos algoritmos de ML, passou-se para a fase de modelação preditiva. Esta etapa teve como objetivo desenvolver e avaliar modelos capazes de prever o estado periodontal de cada indivíduo, com base nas suas características clínicas, comportamentais e demográficas.

Para esta fase, a variável alvo – *target* - foi definida como "Status perio", que representa a classificação binária do estado periodontal das amostras. As variáveis independentes - *features* - foram todas as restantes colunas do *dataset* final, tendo-se removido explicitamente a variável dependente para evitar fuga de informação durante o treino.

Antes de treinar os algoritmos, os dados foram divididos em dois subconjuntos: conjunto de treino (80%) e conjunto de teste (20%), mantendo-se a proporção das classes através da técnica de amostragem estratificada. Devido à presença de variáveis numéricas com diferentes escalas, foi necessário aplicar normalização. A técnica escolhida foi o `StandardScaler`, que transforma as variáveis para uma distribuição com média 0 e desvio padrão 1. Para evitar *data leakage* — isto é, a utilização de informações do conjunto de teste durante o treino —, a normalização foi integrada diretamente nos *pipelines* de cada modelo. Desta forma, em cada etapa de validação cruzada, o *fit* do `StandardScaler` é realizado apenas sobre os dados de treino da dobra correspondente, sendo depois aplicado ao conjunto de teste. Esta abordagem garante consistência, reduz a possibilidade de erros manuais e simula de forma mais fidedigna um cenário de utilização em produção.

Foram avaliados seis algoritmos clássicos de classificação: *Naive Bayes*, *K-Nearest Neighbors*, *Decision Tree*, *Random Forest*, *Support Vector Machine* e Regressão Logística. Para cada modelo, foram definidos conjuntos de hiperparâmetros a testar. A seleção dos melhores hiperparâmetros foi realizada com o método *GridSearch Cross Validation*, que executa uma pesquisa exaustiva combinando todas as possibilidades num esquema de validação cruzada com 5 dobras (*5-fold cross-validation*). O critério de avaliação principal foi a *Accuracy* média nas validações.

Após o treino, os modelos foram avaliados sobre o conjunto de teste. A escolha das métricas mais adequadas está diretamente ligada à natureza da variável alvo que queremos prever, e sendo que esta pes-

quisa enfrenta um problema de classificação binária, foram utilizadas métricas como *Accuracy*, Precisão, *Recall*, *F1-score*, *Receiver Operating Characteristic Curve* (curva ROC) e AUC. Uma vez utilizada a técnica de *cross validation*, os valores finais das métricas que permitirão avaliar os modelos corresponderão à média dos valores que se obtiver no final de cada *k* iteração. A *Accuracy*, definida na Equação 3.1, é uma métrica simples e bastante utilizada, que mede a proporção de previsões corretas (Verdadeiros Positivos - VP e Verdadeiros Negativos - VN) feitas pelo modelo. *Precision*, definido na Equação 3.3, representa a proporção de VP em relação ao total de positivos (VP e Falsos Positivos - FP), e espera-se que o modelo tenha um desempenho tão melhor quanto mais perto de 1 o valor de precisão estiver. *Recall*, definido na Equação 3.2, mede a sensibilidade do modelo ao identificar os casos que são verdadeiros positivos em relação ao total de reais positivos (VP e Falsos Negativos- FN). O *F1-score*, definido na Equação 3.4 poderá ser útil no caso de se ter classes desbalanceadas, podendo complementar a informação dada pela *Accuracy* que é sensível a esse desequilíbrio, sendo que o valor ideal é o mais próximo de 1 possível. Por último, a curva ROC permitirá avaliar a capacidade de discriminação do modelo em problemas de classificação. Um modelo perfeito terá uma curva ROC desenhada no canto superior esquerdo do gráfico, onde a taxa de verdadeiros positivos é igual a 1 e a taxa de falsos positivos é zero (Equação 3.5). A AUC quantifica o desempenho do modelo, sendo que uma AUC igual a 1 revela que o modelo separa as classes com 100% de precisão, uma AUC igual a 0,5 revela que o modelo não tem capacidade de discriminação e que, por isso, não é melhor do que uma escolha aleatória, e, por fim, uma AUC inferior a 0,5 demonstra que o modelo é pior do que uma escolha aleatória.

$$Accuracy = \frac{VP + VN}{VP + FP + FN + VN} \tag{3.1}$$

$$Recall = \frac{VP}{VP + FN} \tag{3.2}$$

$$Precision = \frac{VP}{VP + FP} \tag{3.3}$$

$$F1\text{-}score = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \tag{3.4}$$

$$TFP = \frac{FP}{VN + FP} \tag{3.5}$$

3.5 Tradução do modelo para a Prática Clínica

Para traduzir a análise numa ferramenta aplicável na prática clínica, definiu-se uma metodologia estruturada para selecionar o modelo mais adequado para previsão da DP. Como referido anteriormente, foram treinados vários algoritmos de classificação binária com o objetivo de construir modelos com capacidade preditiva clínica, capazes de discriminar entre pessoas com Saúde Periodontal e pessoas com DP.

Posteriormente, procedeu-se à análise da importância das variáveis, com o objetivo de identificar os preditores mais relevantes para a DP. Esta análise teve como objetivo selecionar tanto um conjunto de variáveis comuns aos modelos mais robustos quanto subconjuntos específicos de *top features* para cada algoritmo. Com base nesta seleção de variáveis, foram definidos cenários de treino distintos:

- um que utilizava todas as variáveis inicialmente incluídas (as 21 variáveis resultantes do pré-processamento);
- outro apenas com as variáveis comuns identificadas;
- um terceiro com os subconjuntos específicos de cada modelo.

Esta abordagem assegura que os modelos de classificação construídos possam ser aplicados de forma prática por médicos dentistas, simplificando a recolha de dados clínicos e biomarcadores sem comprometer a capacidade preditiva. O processo descrito na Figura 6 garante que a construção do modelo, desde a seleção das variáveis até à definição do algoritmo mais adequado, seja sistemática, transparente e passível de aplicação clínica, fornecendo uma base robusta para avaliação do risco periodontal em contexto real.

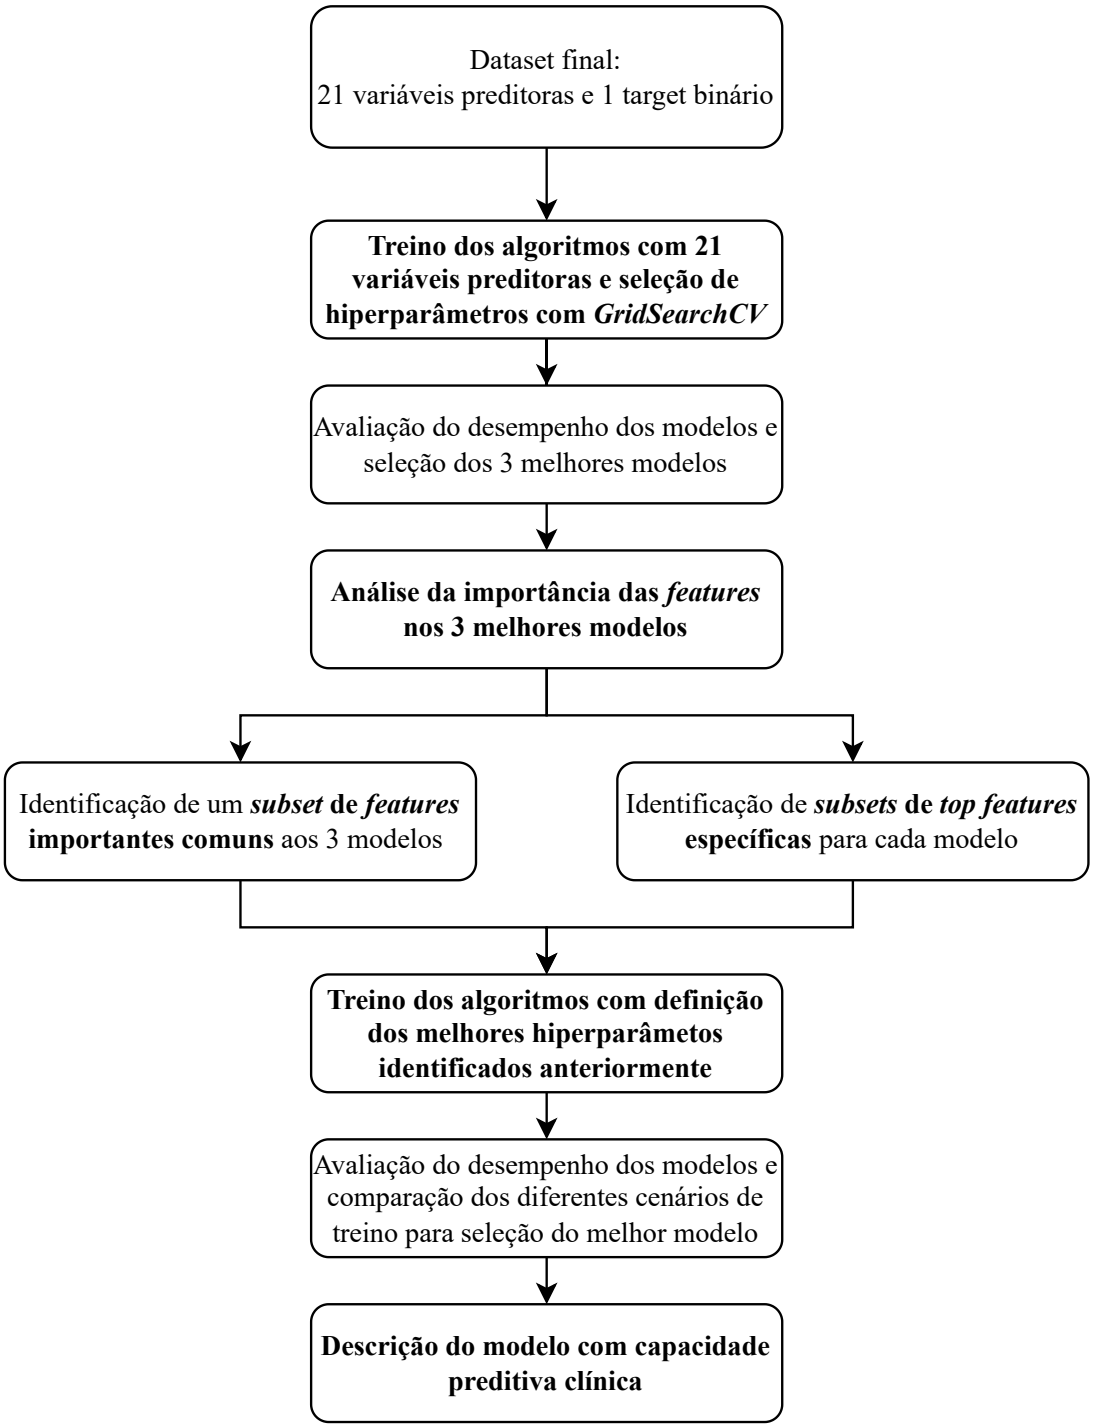

Figura 6: Metodologia adotada para a eleição do melhor modelo com capacidade preditiva clínica.

Capítulo 4

Resultados

Neste capítulo apresentam-se os resultados obtidos na análise dos fatores de risco associados à DP e na avaliação da capacidade preditiva dos vários modelos de ML testados.

4.1 Análise exploratória: principais resultados

Em diversas variáveis, observaram-se distribuições assimétricas à direita, com a presença de *outliers*. No entanto, dada a relevância clínica destas observações — muitas associadas à presença de DP — optou-se por manter estes valores, garantindo representatividade das condições clínicas observadas. Por exemplo, no caso específico da variável "CAL_total", os outliers severos (7,42 mm e 9,73 mm) revelaram-se compatíveis com o estadio IV de periodontite, reforçando a decisão de os manter na análise. De modo semelhante, na variável "No.teeth", a presença de utentes com número reduzido de dentes é clinicamente significativa e informativa para o problema em estudo.

Relativamente ao método de imputação utilizado para o tratamento de valores BDL, a Figura 7 apresenta os mapas de correlação de *Pearson* entre os mediadores inflamatórios *IP-10, IL-1β, MCP-1, IL-6 e IL-8*, antes e depois da imputação dos valores abaixo do limite de deteção. É possível observar que a imputação com *LOD/2* manteve, de forma geral, o padrão de correlação entre os mediadores, sem introduzir alterações substanciais nas relações existentes. Por exemplo, a correlação entre IL-1β e IL-8 manteve-se elevada (0,68), enquanto a relação entre IP-10 e os restantes mediadores permaneceu fraca. De acordo com a literatura, a IL-1β é uma citocina pró-inflamatória central no desencadeamento das respostas imunes inatas, atuando como potente indutora de mediadores inflamatórios e moléculas de adesão celular. Nas doenças inflamatórias orais, como a periodontite, a IL-1β promove a ativação de vias de sinalização intracelular, que estimulam a produção de outras citocinas e quimiocinas, destacando-se a IL-8, uma quimiocina fundamental para o recrutamento e ativação de neutrófilos nos tecidos periodontais

(Chang et al., 2019). Assim, a relação entre IL-1β e IL-8 representa um eixo central na patogénese da periodontite: a primeira atua como indutora da inflamação, enquanto a segunda amplifica o recrutamento celular, perpetuando o processo inflamatório crónico e contribuindo para a destruição tecidual característica da doença (Chang et al., 2019). Estes resultados sugerem que a imputação aplicada preservou as estruturas relacionais dos dados, reforçando a adequação da abordagem utilizada. Gráficos adicionais com as distribuições e comparações detalhadas encontram-se no repositório *GitHub*.

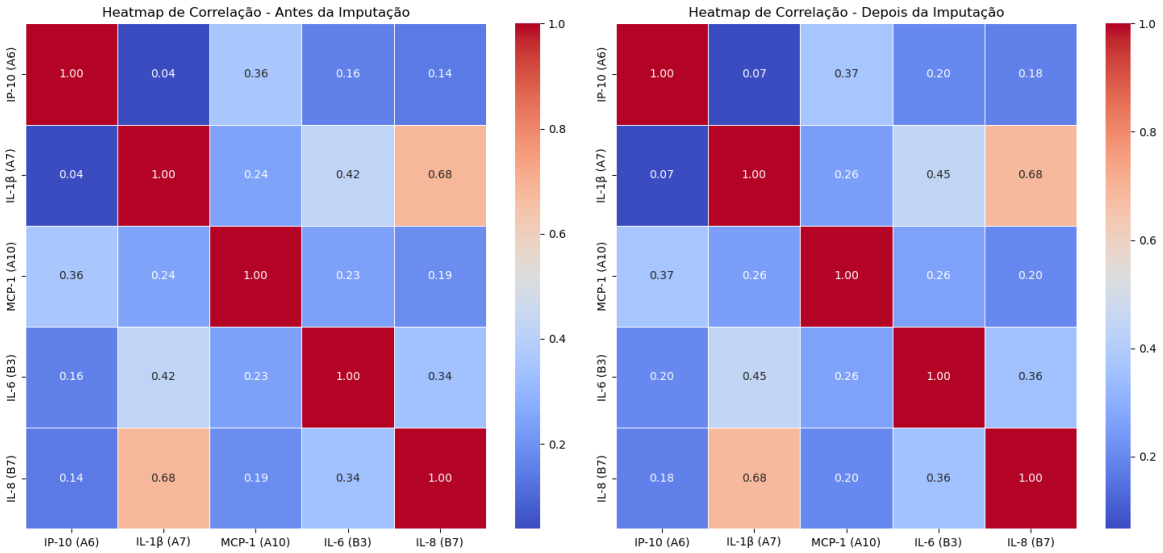

Figura 7: *Heatmaps* de correlação entre os mediadores inflamatórios antes (esquerda) e depois (direita) da imputação dos valores BDL.

Apesar da aplicação da transformação logarítmica aos valores dos mediadores inflamatórios, os dados continuaram a não seguir uma distribuição normal segundo o teste de *Shapiro-Wilk*; no entanto, conforme os exemplos nas Figuras 8 e 9, observaram-se melhorias visíveis na dispersão e simetria, justificando a sua manutenção.

Adicionalmente, com o objetivo de identificar diferenças estatísticas entre os grupos "Saúde Periodontal"e "Doença Periodontal", foi utilizado o teste de *Mann-Whitney*, adequado para amostras independentes com distribuições não normais. A análise revelou diferenças estatisticamente significativas ($p < 0{,}05$) para todos os mediadores, tanto nas variáveis originais quanto nas transformadas com logaritmo (rejeitando-se a Hipótese Nula que diz que não existem diferenças estatisticamente significativas nos níveis dos mediadores inflamatórios entre os indivíduos com Saúde Periodontal e aqueles com DP). Os testes realizados com os mediadores inflamatórios IL-1β, IL-6 e IL-8 foram os que apresentaram um valor de prova mais

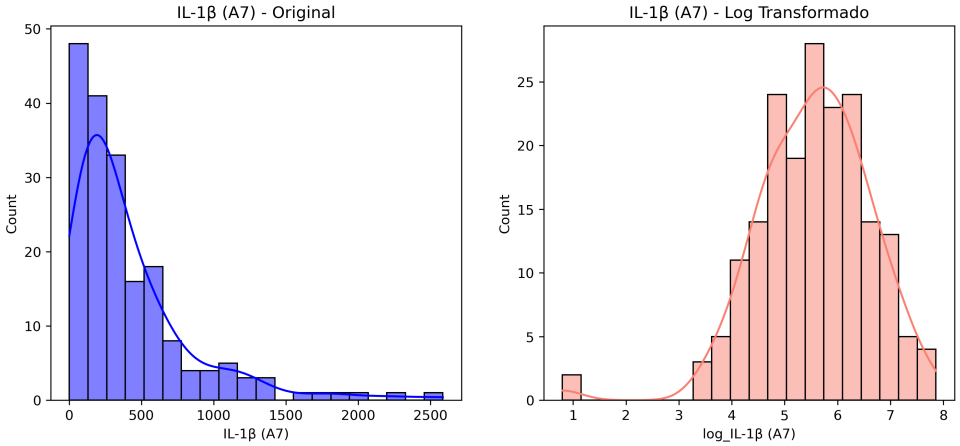

Figura 8: Distribuição do mediador IL-1β antes e depois da transformação logarítmica (*log1p*).

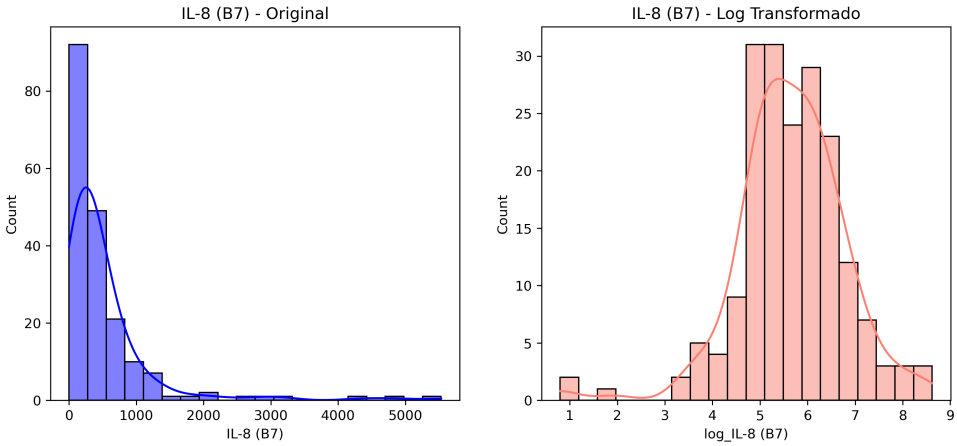

Figura 9: Distribuição do mediador IL-8 antes e depois da transformação logarítmica (*log1p*).

baixo, reforçando, mais uma vez, o papel importante destes mediadores no processo inflamatório associado às doenças periodontais. Estes resultados reforçam o potencial discriminativo dos mediadores selecionados, tornando-os candidatos robustos para inclusão como variáveis preditoras nos modelos de classificação da condição periodontal (Tabela 4).

Tabela 4: Resultados do teste de *Mann-Whitney* para os mediadores inflamatórios selecionados.

Mediador	**U**	**p-value**	**Diferença significativa**
IP-10 (A6)	3416.5	0.0325	Sim
IL-1β (A7)	2532.5	0.0000	Sim
MCP-1 (A10)	3109.5	0.0031	Sim
IL-6 (B3)	2440.5	0.0000	Sim
IL-8 (B7)	2782.5	0.0001	Sim

A divisão do conjunto de dados em treino (80%) e teste (20%) de forma estratificada manteve a proporção original entre as classes "Saúde Periodontal" e "DP". Esta abordagem garantiu a representatividade das classes em ambos os subconjuntos, minimizando enviesamentos na avaliação dos modelos. A Tabela 5 apresenta a distribuição percentual das classes nos conjuntos de treino e teste, confirmando a manutenção do equilíbrio.

Tabela 5: Distribuição percentual de saúde e DP nos conjuntos de treino e teste.

Conjunto	**Saúde Periodontal (%)**	**DP (%)**
Treino	38,3	61,7
Teste	36,8	63,2

4.2 Avaliação do desempenho dos modelos: Contribuição de todas as variáveis

Tal como explicado no capítulo anterior, numa primeira fase, os algoritmos foram treinados com a inclusão das 21 *features* resultantes do processo de pré-processamento dos dados, com o objetivo de estabelecer uma linha base de desempenho. A utilização do conjunto completo de *features* fornece uma visão abrangente da contribuição relativa de cada uma delas e permite compreender a robustez intrínseca de cada algoritmo quando confrontado com um conjunto amplo de preditores.

A avaliação dos modelos foi realizada com base nas métricas de *Accuracy*, precisão, *Recall*,*F1-score* e AUC, calculadas sobre o conjunto de teste, e o resultado do treino dos algoritmos de ML encontra-se descrito na Tabela 6. As curvas ROC encontram-se na Figura 10.

Tabela 6: Desempenho dos modelos de classificação e seleção dos melhores modelos.

Modelo	**Accuracy**	**Precision**	**Recall**	**F1-score**	**AUC**
Naive Bayes	86,8%	100%	79,2%	88,4%	95,5%
K-Nearest Neighbors	84,2%	90,9%	83,3%	87,0%	90,9%
Decision Tree	94,7%	95,8%	95,8%	95,8%	94,5%
Random Forest	**94,7%**	**100%**	**91,7%**	**95,6%**	**100%**
Support Vector Machine	**94,7%**	**100%**	**91,7%**	**95,6%**	**98,5%**
Regressão Logística	**94,7%**	**100%**	**91,7%**	**95,6%**	**98,8%**

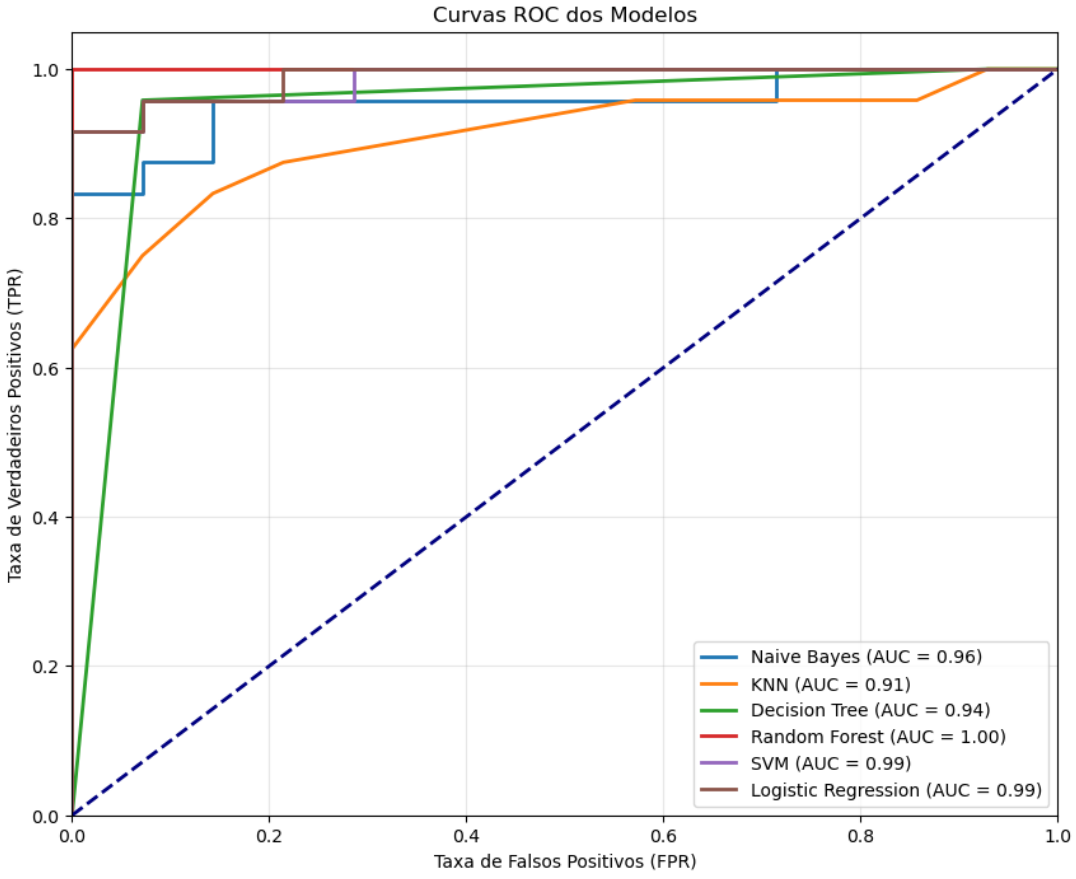

Figura 10: Curvas ROC.

Os modelos baseados em árvores (*Decision Tree* e *Random Forest*), assim como *Support Vector Machine* e Regressão Logística, evidenciaram um desempenho superior, com elevados valores de *accuracy* e AUC, o que indica uma capacidade robusta de identificar corretamente a presença da DP. O modelo

Naive Bayes apresentou alta precisão, sugerindo que quando prevê a DP, o faz com grande confiança, mas com *Recall* inferior, significando que nem todos os casos foram corretamente identificados, o que pode resultar em FN. O *K-Nearest Neighbors* teve um desempenho ligeiramente inferior, possivelmente devido à sensibilidade do modelo à configuração do número de vizinhos e à natureza dos dados.

As matrizes de confusão para cada modelo, apresentadas na Figura 11, fornecem uma visão detalhada da distribuição de classificações corretas e incorretas realizadas no conjunto de teste, evidenciando os níveis de FP e FN que influenciam as métricas de *Recall* e precisão. Neste caso, os três melhores modelos apresentam exatamente o mesmo número de falsos negativos (dois), indo de encontro aos valores apresentados na Tabela 6 para cada um dos modelos. Ou seja, em 38 amostras pertencentes ao conjunto de teste, os três modelos apenas classificaram incorretamente dois casos, nomeadamente, atribuíram a classificação "Saúde Periodontal"a dois casos que correspondiam à categoria "Doença Periodontal".

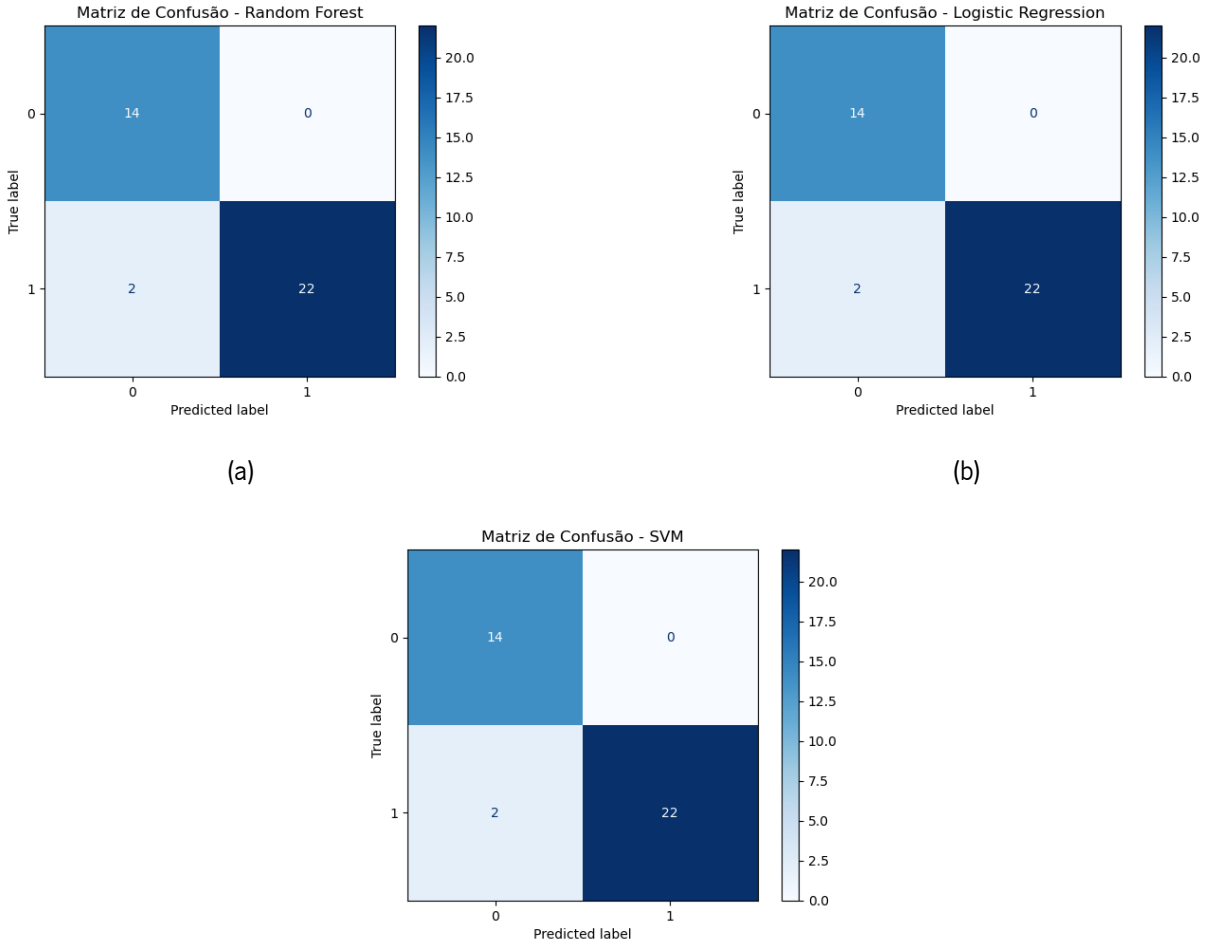

Figura 11: Matrizes de Confusão dos três modelos com melhor desempenho ((a) - *Random Forest* , (b) - Regressão Logística e (c) - *Support Vector Machine*).

Foi ainda realizada uma análise da importância relativa das variáveis para os 3 melhores modelos selecionados. No modelo *Random Forest* (Figura 12), embora a percentagem de sangramento à sondagem total seja a variável mais importante, com um peso de 39% na decisão do modelo, outras variáveis clínicas como a percentagem total de placa, a profundidade de sondagem, a perda clínica de inserção, a presença de DM, os valores de alguns mediadores inflamatórios (IL-1β, IL-8, IL-6 e MCP-1) e o fator idade também tiveram influência significativa na previsão do modelo.

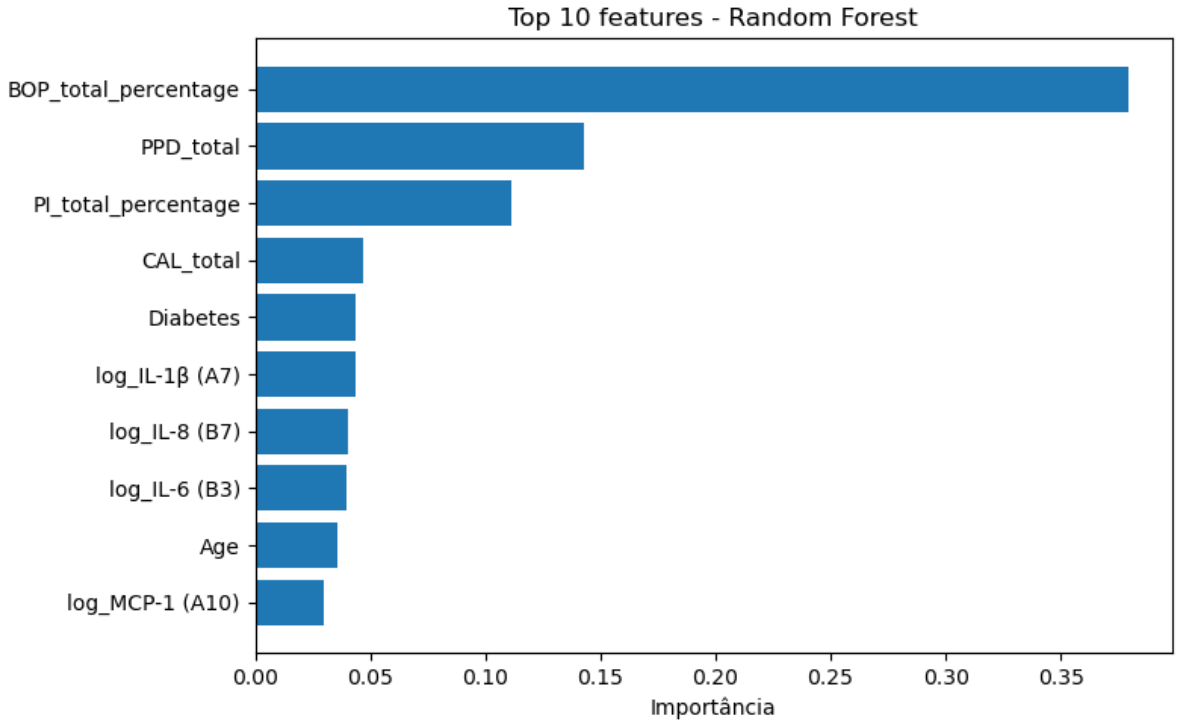

Figura 12: Análise da importância das *features*: *Random Forest*.

No modelo *Support Vector Machine* (Figura 13), a percentagem de sangramento à sondagem total continua a ter o peso maioritário para a decisão do modelo. Segue-se a profundidade de sondagem, o número de cigarros fumados por dia, a percentagem total de placa, alguns mediadores inflamatórios (IL-8, IL-6 e IP-10), o número de dentes presentes, o sexo e o ser/não ser fumador ativo.

Por último, para o modelo de Regressão Logística (Figura 14) a percentagem total de sangramento à sondagem foi novamente um fator decisivo. Seguiu-se a profundidade de sondagem, a percentagem total de placa, alguns mediadores inflamatórios (IL-1β, IL-8, IL-6 e MCP-1), o número de cigarros por dia, o número de dentes presentes e o número de vezes que realizam a higiene oral.

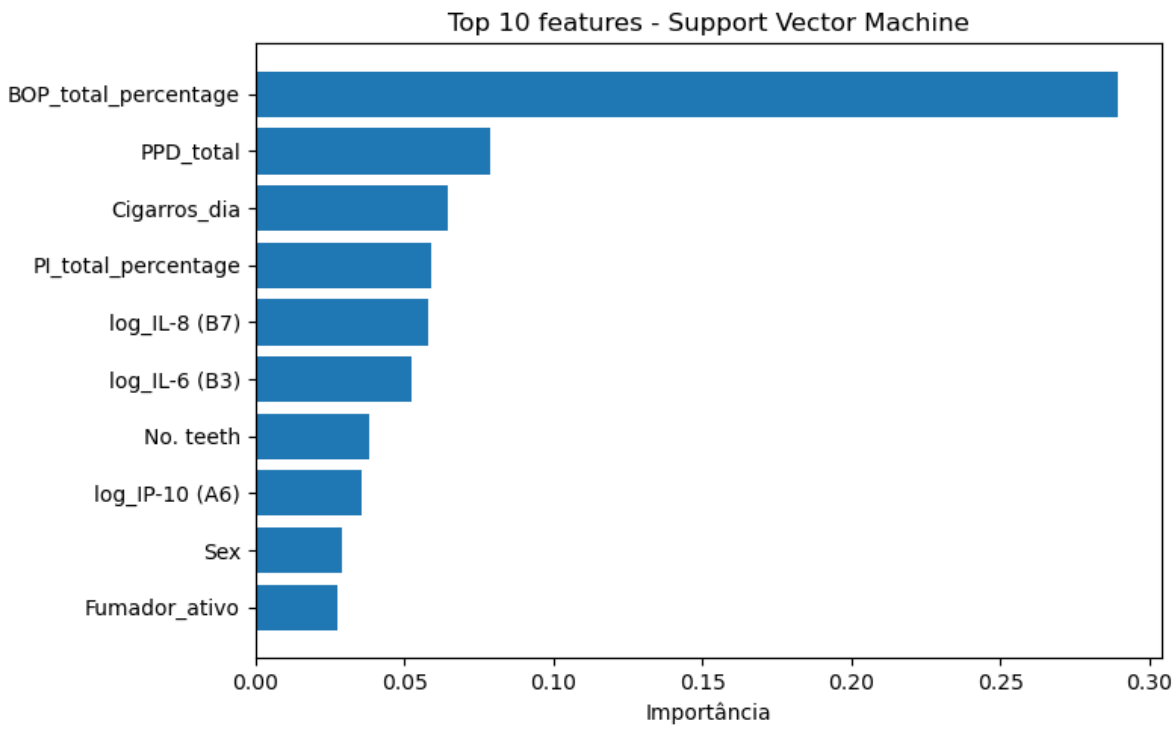

Figura 13: Análise da importância das *features*: *Support Vector Machine*.

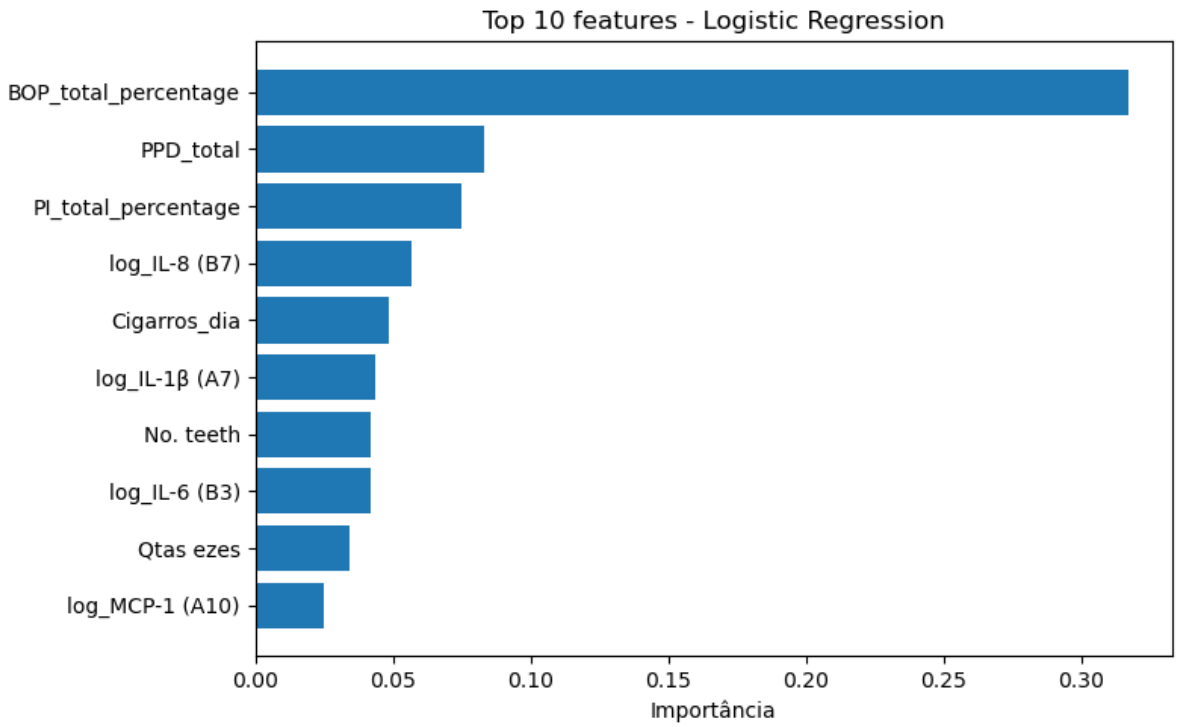

Figura 14: Análise da importância das *features*: *Regressão Logística*.

4.3 Avaliação do desempenho dos modelos: Contribuição de um subset de variáveis comuns

Neste subcapítulo, descrevem-se os resultados da análise realizada com base nas variáveis comuns identificadas como mais importantes nos três modelos mais robustos (*Random Forest*, Regressão Logística e *Support Vector Machine*). O subconjunto incluiu medidas clínicas clássicas, como BOP_total_percentage, PPD_total e PI_total_percentage, assim como marcadores inflamatórios (log_IL-6 e log_IL-8). O objetivo desta abordagem foi avaliar se a simplificação do modelo, reduzindo o número de variáveis para aquelas que apresentam maior relevância compartilhada entre algoritmos, poderia manter ou até melhorar o desempenho dos modelos. Esta estratégia reflete a preocupação em tornar os modelos clinicamente aplicáveis na prática diária, facilitando a recolha de dados e a interpretação dos resultados pelos médicos dentistas, sem comprometer a discriminação entre utentes saudáveis e com DP.

Qualitativamente, o *Random Forest* manteve um desempenho consistente, demonstrando robustez em cenários com diferentes combinações de variáveis. A Regressão Logística alcançou o melhor desempenho neste cenário, evidenciando que a seleção de variáveis altamente relevantes facilita a modelação linear e a interpretação clínica. O *Support Vector Machine* também apresentou melhoria no seu desempenbho, mostrando que a redução de variáveis menos informativas permite definir um hiperplano de separação mais preciso.

Do ponto de vista quantitativo, o *Random Forest* apresentou AUC próximo de 0,997, mantendo *Accuracy* de 0,947 e *F1-score* de 0,957. A Regressão Logística registou melhoria com *Accuracy* de 0,974, *F1-score* de 0,979 e AUC de 0,988, enquanto o *Support Vector Machine* também melhorou ligeiramente, com *Accuracy* de 0,947, *F1-score* de 0,957 e AUC de 0,991. Estes resultados indicam que o conjunto reduzido de cinco variáveis comuns é suficiente para manter ou até aumentar a performance, tornando o modelo mais prático para aplicação clínica.

4.4 Avaliação do desempenho dos modelos: Contribuição de subsets de variáveis específicas para cada modelo

Para explorar o potencial máximo de cada algoritmo, os modelos foram treinados utilizando os *subsets* de *top features* específicos de cada modelo, identificadas na análise de importância das variáveis.

Qualitativamente, o *Random Forest* manteve desempenho consistente e robusto. A Regressão Logística atingiu o melhor desempenho dentro dos três cenários testados, mostrando beneficiar da seleção de variáveis altamente relevantes, enquanto o *Support Vector Machine* apresentou melhoria no ajuste do hiperplano de separação, refletindo a eliminação de variáveis menos informativas.

Do ponto de vista quantitativo, o *Random Forest* manteve AUC de 1,000, *Accuracy* de 0,947 e *F1-score* de 0,957. A Regressão Logística apresentou AUC máxima de 1,000, com *Accuracy* de 0,974 e *F1-score* de 0,979, enquanto o *Support Vector Machine* também atingiu AUC de 1,000, com *Accuracy* de 0,974 e *F1-score* de 0,979. Estes resultados indicam que a utilização de *subsets* específicos permite maximizar a capacidade preditiva dos modelos, sendo particularmente útil em contextos clínicos, onde se pretende obter previsões mais detalhadas e precisas para cada utente.

4.5 Regressão Logística: Aplicação Clínica

Após a comparação dos diferentes cenários testados (Tabela 7), o modelo selecionado como o modelo mais adequado para aplicação clínica foi a Regressão Logística com o conjunto de variáveis específicas. Esta escolha fundamentou-se no facto de o modelo que utilizou Regressão Logística ter apresentado um desempenho equivalente ou superior aos restantes algoritmos em todas as métricas avaliadas, atingindo AUC perfeita (1,00) e valores elevados de *Accuracy* (0,974) e *F1-score* (0,979) e, para além da elevada performance, por possuir a vantagem de permitir a interpretação direta dos coeficientes associados a cada variável, traduzindo-os em OR que quantificam de forma clara a influência de cada fator de risco no desenvolvimento da DP. Esta característica torna o modelo particularmente relevante em contexto clínico, uma vez que não se limita a fornecer uma previsão do estado periodontal (saúde/doença), mas também fornece informação interpretável sobre a contribuição de cada variável. Assim, o modelo funciona simultaneamente como uma ferramenta de classificação e como um modelo preditivo com capacidade explicativa, apoiando a tomada de decisão por parte dos médicos dentistas.

4.5.1 Variáveis a incluir

O modelo final de Regressão Logística foi treinado com um subconjunto de dez variáveis identificadas na análise de importância da *features* como tendo maior peso relativo na decisão do modelo. Estas variáveis refletem tanto parâmetros clínicos de avaliação periodontal como fatores de risco comportamentais e biomarcadores inflamatórios. Em conjunto, permitem uma caracterização abrangente do estado

Tabela 7: Desempenho dos modelos considerando diferentes conjuntos de variáveis. O modelo destacado em negrito, Regressão Logística com *Top Features* específicas, foi escolhido como o mais adequado para aplicação clínica, devido ao seu equilíbrio entre AUC perfeita, alta *Accuracy* e *F1-score*, e facilidade de interpretação do modelo.

Modelo	**Features**	**Accuracy**	**Precision**	**Recall**	**F1**	**AUC**
Random Forest	Todas	0.947	1.0	0.917	0.957	1.000
Random Forest	Comuns	0.947	1.0	0.917	0.957	0.997
Random Forest	Top específicas	0.947	1.0	0.917	0.957	1.000
Regressão Logística	Todas	0.947	1.0	0.917	0.957	0.988
Regressão Logística	Comuns	0.974	1.0	0.958	0.979	0.988
Regressão Logística	**Top específicas**	**0.974**	**1.0**	**0.958**	**0.979**	**1.000**
Support Vector Machine	Todas	0.947	1.0	0.917	0.957	0.985
Support Vector Machine	Comuns	0.947	1.0	0.917	0.957	0.991
Support Vector Machine	Top específicas	0.974	1.0	0.958	0.979	1.000

periodontal e do risco de progressão da doença.

As variáveis incluídas foram:

- BOP_total_percentage: Percentagem total de sangramento à sondagem (%), indicador da inflamação gengival ativa;
- PPD_total: Profundidade de sondagem total (mm), refletindo a gravidade da destruição periodontal;
- PI_total_percentage: Percentagem total do índice de placa (%), associada ao controlo da higiene oral;
- log_IL-8 (B7): Nível transformado da IL-8 (pg/mL), biomarcador inflamatório relacionado com a resposta imunitária local;
- Cigarros_dia: Número de cigarros fumados por dia (unidades/dia), fator de risco reconhecido para periodontite;
- log_IL-1β (A7): Nível transformado da IL-1β (pg/mL), marcador pró-inflamatório fortemente associado à destruição tecidual;

- No. teeth: Número total de dentes presentes (unidades), refletindo o histórico de saúde oral do utente;
- log_IL-6 (B3): Nível transformado da IL-6 (pg/mL), biomarcador inflamatório associado a processos crónicos;
- Qtas ezes: Frequência de escovagem dentária diária (vezes/dia), variável comportamental relacionada com higiene oral;
- log_MCP-1 (A10): Nível transformado da proteína quimioatrativa de monócitos (MCP-1, pg/mL), envolvida no recrutamento celular inflamatório.

Estas variáveis representam um equilíbrio entre fatores clínicos tradicionais e medições laboratoriais específicas, garantindo que o modelo não só identifica corretamente os utentes com DP, mas também fornece informação adicional sobre os mecanismos subjacentes ao risco.

4.5.2 Coeficientes e interpretação do modelo

A interpretação dos coeficientes da Regressão Logística é feita através da conversão dos betas (β) em OR, calculados como e^{β}. Os OR permitem quantificar o impacto relativo de cada variável na probabilidade de ocorrência da DP.

- Coeficientes positivos (OR > 1) indicam um aumento das *odds* de DP.
- Coeficientes negativos (OR < 1) indicam uma redução das *odds*.
- O intercepto ($\beta_0 = 5.2318$) ajusta a escala global do modelo, mas não possui interpretação clínica direta isoladamente.

A Tabela 8 apresenta os coeficientes da regressão logística para cada variável, os OR correspondentes e a interpretação em termos de alteração relativa no risco de DP.

Tabela 8: Coeficientes, Odds Ratios e interpretação clínica do modelo de Regressão Logística com Top Features específicas.

Variável	**Coeficiente (β)**	**OR = e^{β}**	**Interpretação**
BOP_total_percentage	7.4197	1670.7	Cada aumento de 1% no BOP multiplica as *odds* em $\sim$1670x
PPD_total	1.4394	4.22	Cada mm adicional de profundidade aumenta as *odds* em 322%
PI_total_percentage	0.8359	2.31	Cada aumento de 1% no PI duplica aproximadamente as *odds*
log_IL-8 (B7)	0.1595	1.17	Cada aumento unitário em IL-8 aumenta as *odds* em 17%
Cigarros_dia	0.1028	1.11	Cada cigarro adicional aumenta as *odds* em 11%
log_IL-1β (A7)	-0.4564	0.63	Cada aumento unitário em IL-1β reduz as *odds* em 37%
No. teeth	-0.9929	0.37	Cada dente a mais reduz as odds em 63%
log_IL-6 (B3)	0.2323	1.26	Cada aumento unitário em IL-6 aumenta as *odds* em 26%
Qtas ezes	0.5141	1.67	Cada escovagem adicional aumenta as *odds* em 67%
log_MCP-1 (A10)	0.1876	1.21	Cada aumento unitário em MCP-1 aumenta as *odds* em 21%

4.5.3 Thresholds de decisão

O modelo de Regressão Logística apresentou alta precisão na deteção de DP em todos os *thresholds* testados (Figura 15), indicando que as previsões positivas são confiáveis. O *Recall* apresentou uma leve queda com *thresholds* mais elevados, refletindo aumento de falsos negativos, enquanto o *F1-score* mostrou que *thresholds* entre 0,5 e 0,6 oferecem melhor equilíbrio entre sensibilidade e precisão. O histograma das probabilidades previstas (Figura 16) evidenciou boa separação entre utentes saudáveis e doentes, com poucas observações próximas ao *threshold* de 0,5, sugerindo que o modelo consegue distinguir claramente as classes.

4.5.4 Receita clínica para aplicação do modelo

O modelo de Regressão Logística com *Top Features* específicas, eleito como o mais adequado para aplicação clínica, permite aos profissionais de saúde estimar o risco individualizado de DP de um utente com base em variáveis clínicas e biomarcadores selecionados. Atualmente, o modelo encontra-se implementado em ambiente *Python*, podendo ser executado através de um *script* que recebe dados estruturados num ficheiro .csv ou *DataFrame*. Futuramente, este funcionamento pode ser facilmente integrado numa aplicação com *interface* gráfica, onde o médico periodontologista insere os dados num formulário e recebe automaticamente a probabilidade de risco.

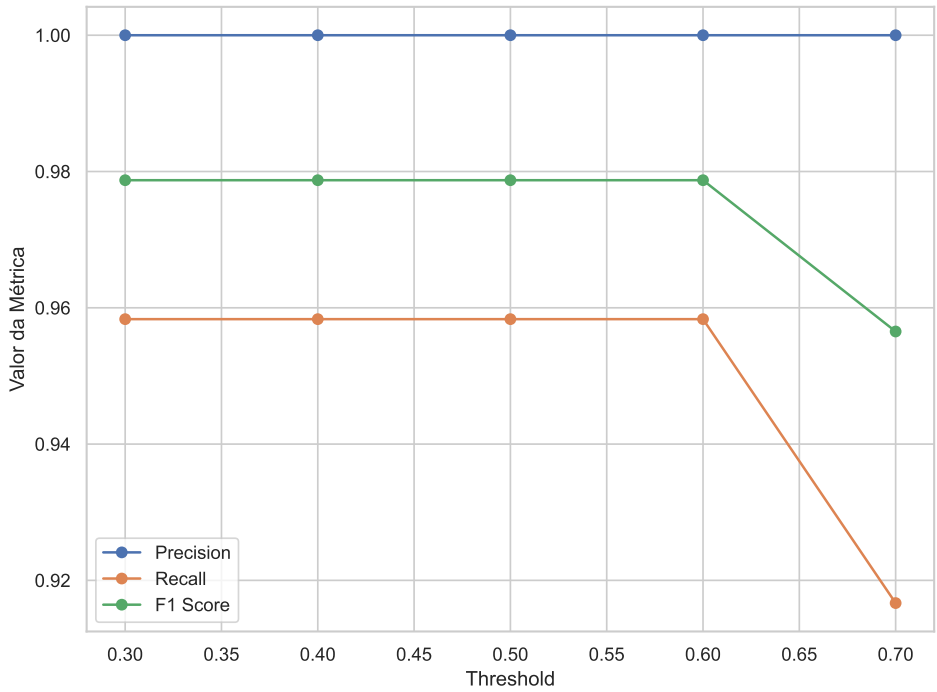

Figura 15: Desempenho do modelo de Regressão Logística (*Top Features*) em diferentes thresholds.

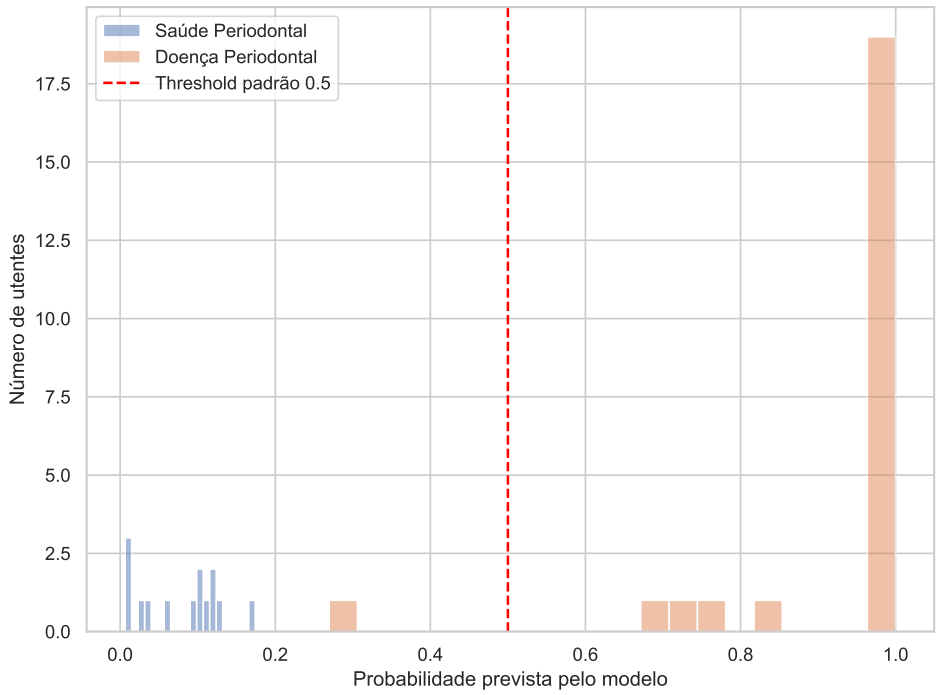

Figura 16: Distribuição das probabilidades previstas pelo modelo de Regressão Logística para utentes com Saúde Periodontal e utentes com Doença Periodontal. A linha vermelha indica o *threshold* padrão de 0,5.

O procedimento para utilização do modelo deve incluir os seguintes passos:

1. **Colheita das variáveis necessárias:** Para cada pessoa, devem ser registadas as dez variáveis consideradas no modelo:

    - Percentagem total de sangramento à sondagem (%) (x_1)
    - Profundidade de sondagem total (mm) (x_2)
    - Percentagem total do índice de placa (%) (x_3)
    - IL-8 (B7) (pg/mL) (x_4)
    - Número de cigarros fumados por dia (unidades/dia) (x_5)
    - IL-1β (A7) (pg/mL) (x_6)
    - Número total de dentes presentes (unidades) (x_7)
    - IL-6 (B3) (pg/mL) (x_8)
    - Frequência de escovagem dentária diária (vezes/dia) (x_9)
    - MCP-1 (A10) (pg/mL) (x_{10})

2. **Preparação dos dados:** Os valores de cada variável devem ser inseridos na mesma unidade e escala utilizadas no treino do modelo. No caso dos marcadores inflamatórios, se existirem valores BDL, estes deverão ser substituídos por LOD/2 de acordo com os valores de LOD definidos nos *kits* de quantificação utilizados, indo de encontro ao procedimento adotado neste estudo. Isto significa que para a correta utilização futura numa aplicação, seria necessário fornecer, para além dos valores dos mediadores inflamatórios, um dicionário ou tabela com os valores de LOD correspondentes a cada *kit* de quantificação. Para além disso, de seguida, deve-se aplicar a transformação logarítmica. Para utilização prática do modelo, os profissionais de saúde inseririam os valores medidos diretamente no sistema clínico ou aplicação. Os marcadores inflamatórios seriam transformados internamente pela aplicação antes de serem processados pelo modelo. Assim, o profissional de saúde não precisa de realizar cálculos ou transformações adicionais, precisando apenas de fornecer os dados brutos, garantindo a precisão e facilidade de utilização.

3. **Aplicação da equação do modelo:** O risco de DP (p) é calculado através da função logística:

$$p(\text{DP}) = \frac{1}{1 + e^{-z}}$$

onde:

$$
\begin{aligned}
z = {} & 5.2318 + 7.4197 \cdot x_1 + 1.4394 \cdot x_2 + 0.8359 \cdot x_3 \\
& + 0.1595 \cdot x_4 + 0.1028 \cdot x_5 - 0.4564 \cdot \ln(1 + x_6) \\
& - 0.9929 \cdot x_7 + 0.2323 \cdot \ln(1 + x_8) + 0.5141 \cdot x_9 + 0.1876 \cdot \ln(1 + x_{10})
\end{aligned}
$$

4. **Interpretação do resultado:** O *output* p representa a probabilidade estimada de o utente ter DP. Valores próximos de 1 indicam alto risco, enquanto valores próximos de 0 indicam baixo risco. Este resultado pode ser utilizado pelos profissionais para priorizar intervenções preventivas ou terapêuticas. Na prática clínica, recomenda-se considerar diferentes pontos de corte (*thresholds*) para decisão:

   - *Threshold* padrão (0,5): proporciona um bom equilíbrio entre a deteção de utentes com DP e a redução de falsos positivos.
   - *Threshold* mais baixo (<0,5): aumenta a sensibilidade, sendo útil quando o objetivo é identificar todos os utentes com DP, sendo mais permissivo na aceitação de alguns falsos positivos.
   - *Threshold* mais alto (>0,6): aumenta a confiabilidade das previsões de Saúde Periodontal, mas pode deixar de detetar alguns utentes com DP, elevando o risco de falsos negativos.

Exemplo prático de aplicação clínica

Na prática clínica, o profissional de saúde introduz apenas os valores brutos das variáveis. A aplicação clínica desenvolvida deverá realizar automaticamente a transformação $\log(1 + x)$ dos biomarcadores e a normalização de todas as variáveis, garantindo que os dados de entrada estejam na mesma escala utilizada durante o treino do modelo. Os parâmetros específicos do modelo, nomeadamente médias e desvios padrão encontram-se detalhados no Apêndice A. Considerando um paciente com as características apresentadas na Tabela 9:

Substituindo os valores normalizados na equação logística anteriormente definida:

$$
\begin{aligned}
z \approx {} & 5.2318 + 7.4197 \cdot (0.53) + 1.4394 \cdot (3.48) + 0.8359 \cdot (-0.31) \\
& + 0.1595 \cdot (-3.37) + 0.1028 \cdot (0.73) - 0.4564 \cdot (-2.67) \\
& - 0.9929 \cdot (0.18) + 0.2323 \cdot (-1.08) + 0.5141 \cdot (-0.40) + 0.1876 \cdot (-5.15) \\
\approx {} & 14.03
\end{aligned}
$$

Tabela 9: Exemplo de processamento dos dados de um paciente: valores brutos, transformação $\log(1+x)$ (apenas biomarcadores) e valores normalizados pelo *StandardScaler*.

Variável	Valor bruto	$\log(1+x)$	Valor normalizado
Percentagem de sangramento (%)	30	–	0.53
Profundidade de sondagem (mm)	5	–	3.48
Índice de placa (%)	25	–	-0.31
IL-8 (pg/mL)	2.2	1.16	-3.37
Cigarros por dia	5	–	0.73
IL-1β (pg/mL)	3.0	1.39	-2.67
Número de dentes	28	–	0.18
IL-6 (pg/mL)	2.3	1.20	-1.08
Escovagem diária (vezes)	2	–	-0.40
MCP-1 (pg/mL)	1.6	0.96	-5.15

A probabilidade prevista pelo modelo é:

$$p = \frac{1}{1+e^{-z}} = \frac{1}{1+e^{-14.03}} \approx 0.999999 \ (\sim 1.00).$$

Ou seja, considerando o *threshold* padrão de 0,5, este utente seria classificado como portador de DP.

Capítulo 5

Discussão

O presente trabalho teve como objetivo explorar o potencial de modelos de ML na previsão da DP, a partir de dados clínicos, sociodemográficos, comportamentais e moleculares. Ao longo do *workflow* desenvolvido — desde a recolha e pré-processamento de dados até ao treino dos algoritmos e avaliação dos modelos — foi possível identificar variáveis-chave associadas ao risco de DP e avaliar a capacidade discriminativa de diferentes abordagens preditivas. A discussão que se segue reflete esta sequência metodológica, permitindo relacionar os principais resultados obtidos com a literatura existente.

Os resultados obtidos neste estudo evidenciam que a percentagem total de sangramento à sondagem se destaca como um dos principais fatores preditivos da DP. Este resultado está alinhado com estudos prévios que identificam o sangramento à sondagem como um indicador clínico fundamental para a inflamação gengival e progressão da DP (European Federation of Periodontology, 2021) (Bishop, 2021) (Marotz et al., 2022). Quer na condição de gengivite, como na condição de periodontite, ambas inseridas na categoria de DP, o sangramento é um sinal clínico inequívoco, sendo que na gengivite pode manifestar-se como sangramento fácil à escovagem, por exemplo, e, na periodontite, poderá mesmo ser espontâneo.

Através de testes estatísticos conseguimos perceber o potencial do estudo dos marcadores inflamatórios no diagnóstico da DP. Todos os mediadores inflamatórios incluídos no treino dos algoritmos demonstraram diferenças estatisticamente significativas entre as duas categorias em estudo ("Saúde Periodontal"e "Doença Periodontal"). Para além disso, nos três melhores modelos selecionados, os mediadores inflamatórios IL-1β, IL-6 e IL-8 destacaram-se como biomarcadores da condição de DP, indo de encontro a estudos já realizados (Relvas et al., 2024). Nesse contexto, os diagnósticos baseados em saliva podem ser utilizados rotineiramente por periodontologistas para o diagnóstico precoce da DP, assim como para a monitorização, prognóstico e gestão da DP através da deteção de biomarcadores, cuja validade diagnós-

tica está relacionada com a sensibilidade e especificidade. Estes resultados vão de encontro à literatura e reforçam a importância de mediadores inflamatórios específicos como indicadores clínicos e potenciais alvos terapêuticos na DP (Cafiero et al., 2021) (Relvas et al., 2024).

Além disso, a análise da importância das *features* revelou uma distribuição ampla da importância das variáveis, com destaque para outros parâmetros clínicos como o índice de placa, a profundidade de sondagem e a perda clínica de inserção, o histórico de DM e tabagismo. Esta diversidade de variáveis reforça a complexidade da DP e a necessidade de considerar múltiplos fatores de risco para uma avaliação mais robusta. Estes achados corroboram a natureza multifatorial da DP, onde fatores locais, sistémicos e comportamentais interagem para influenciar o risco e a severidade da condição (Papapanou et al., 2018) (Steffens and Marcantonio, 2018).

Os modelos de ML demonstraram ter um elevado desempenho, com *Accuracy* acima de 84% em todos os casos, e modelos como *Decision Tree, Random Forest, Support Vector Machine* e Regressão Logística alcançaram valores superiores a 94%. Este desempenho reforça o potencial das técnicas computacionais na identificação precoce e previsão da DP, que podem auxiliar os profissionais de saúde na tomada de decisão clínica. Embora diferentes métricas de desempenho tenham sido calculadas para avaliar os modelos — *Accuracy*, *Precision*, *Recall* e *F1-score* — a métrica central para a eleição dos melhores classificadores foi a AUC. Esta escolha justifica-se pelo facto de a AUC refletir a capacidade discriminativa global do classificador independentemente do limiar de decisão, oferecendo assim uma medida mais robusta do que a *Accuracy*, que pode ser enviesada em cenários de classes desbalanceadas. Além disso, a AUC é particularmente adequada em contextos clínicos, uma vez que equilibra a sensibilidade e a especificidade, dimensões críticas para reduzir falsos negativos e falsos positivos em diagnósticos de DP.

A escolha da Regressão Logística com *Top Features* específicas como modelo final não se justifica apenas pelo desempenho quase perfeito (AUC = 1.0, elevada *Accuracy*, *Precision* e *F1-score*), mas também pela sua interpretabilidade e aplicabilidade clínica. Comparativamente a modelos mais complexos como *Random Forest* ou *Support Vector Machine*, a Regressão Logística oferece coeficientes facilmente traduzíveis em ORs, permitindo compreender o peso relativo de cada variável no risco de doença. Este aspeto é particularmente relevante para profissionais de saúde, que necessitam não apenas de previsões precisas, mas também de explicações transparentes para fundamentar as decisões clínicas.

A análise dos coeficientes da Regressão Logística com *Top Features* específicas evidencia quais são as variáveis que contribuem mais fortemente para o risco de DP. Variáveis como a percentagem total de sangramento à sondagem, a profundidade de sondagem total e a percentagem total do índice de placa apresentam ORs muito elevados (1670, 4,22 e 2,31, respetivamente), indicando que mesmo um aumento pequeno nestes parâmetros clínicos está associado a aumentos substanciais nas *odds* de DP. Importa, contudo, salientar que o modelo trabalha em termos de *odds*, que expressam a razão entre a probabilidade de ocorrência e de não ocorrência da doença. Para aplicação clínica, estas *odds* são automaticamente convertidas em probabilidades pela função logística, tornando o *output* mais intuitivo (valores próximos de 1 = alto risco de ter DP; próximos de 0 = baixo risco de ter DP). Para além disso, é importante reforçar que os coeficientes refletem efeitos ajustados das variáveis, ou seja, consideram o impacto de todas as *features* no modelo. Variáveis com baixa colinearidade, como tabagismo ou frequência de escovagem, têm interpretação direta, enquanto marcadores inflamatórios ou variáveis clínicas correlacionadas devem ser interpretados dentro do contexto do conjunto de variáveis. Assim, o modelo deve ser usado como uma ferramenta de predição conjunta, fornecendo aos profissionais de saúde uma visão integrada do risco de DP, em vez de avaliar cada fator isoladamente. Por exemplo, o coeficiente positivo observado para a variável "Qtas ezes" (frequência de escovagem diária) no modelo de Regressão Logística não implica que escovar mais vezes seja indicativo de maior probabilidade de diagnóstico de DP. Este efeito reflete o ajuste multivariado do modelo, ou seja, o impacto da variável considerando todas as outras características simultaneamente. Na prática clínica, pacientes com pior saúde periodontal (maior BOP, PPD ou PI) podem escovar com mais frequência em resposta às suas condições, gerando uma correlação positiva dentro do conjunto de dados. Portanto, a interpretação deve considerar que a escovagem continua a ser um fator protetor, e o coeficiente positivo apenas indica a associação estatística observada após ajuste pelas restantes variáveis do modelo.

Outra mais-valia do modelo foi a sua robustez em diferentes *thresholds*. A análise das curvas de desempenho mostrou elevada precisão e sensibilidade para limiares entre 0,05 e 0,6, garantindo deteção fiável de casos de DP sem comprometer em excesso a taxa de falsos positivos. Além disso, a distribuição das probabilidades preditas evidenciou uma clara separação entre "Saúde Periodontal"e "Doença Periodontal", reduzindo a ambiguidade nas classificações.

Algumas limitações devem ser apontadas. A amostra utilizada é relativamente pequena e os resultados podem não generalizar para populações distintas sem validação externa. Estudos futuros poderão beneficiar do aumento do tamanho da amostra, o que permitirá obter modelos mais robustos e generalizáveis

a diferentes populações. Uma amostra maior também possibilitaria a inclusão de variáveis adicionais e a exploração de subgrupos clínicos, contribuindo para uma compreensão mais detalhada dos fatores de risco da DP. Além disso, a validação externa dos modelos em diferentes contextos clínicos é fundamental para garantir a sua aplicabilidade prática. A integração destes modelos preditivos em plataformas clínicas pode fomentar a personalização do diagnóstico e o desenvolvimento de estratégias de prevenção ajustadas ao perfil de risco individual de cada paciente.

Em síntese, este trabalho evidencia que os modelos de ML - e em particular a Regressão Logística - podem constituir uma ferramenta valiosa na análise de fatores de risco e na previsão da DP. Através de um *pipeline* robusto e reproduzível, foi possível demonstrar a utilidade de variáveis clínicas clássicas, como o sangramento à sondagem e a profundidade de sondagem, bem como a importância de fatores sistémicos como a diabetes. Este contributo reforça o papel do ML como complemento às abordagens tradicionais, potenciando uma prática clínica mais informada, preventiva e personalizada.

Parte III

Considerações Finais

Capítulo 6

Conclusão

A presente dissertação permitiu demonstrar o potencial dos algoritmos de ML na previsão da DP, com base na integração de fatores clínicos, comportamentais, sociodemográficos e moleculares. A análise dos dados recolhidos evidenciou que variáveis clássicas, como idade, tabagismo, DM e número de dentes, bem como mediadores inflamatórios salivares (nomeadamente IL-1β, IL-6 e IL-8), constituem preditores relevantes da condição periodontal.

Entre os modelos avaliados, destacaram-se *Random Forest*, *Support Vector Machine* e Regressão Logística que apresentaram melhor desempenho na classificação entre saúde periodontal e doença, evidenciando elevada capacidade discriminativa. Estes resultados confirmam que o ML pode atuar como uma ferramenta complementar às abordagens clínicas tradicionais, apoiando o diagnóstico precoce, a estratificação do risco e a personalização da intervenção. Para além disso, o caráter inovador da integração de biomarcadores salivares reforça o potencial destas metodologias na medicina de precisão em saúde oral.

Apesar dos resultados promissores, importa reconhecer algumas limitações do estudo, nomeadamente o tamanho reduzido da amostra e a ausência de validação externa em contextos clínicos distintos. Estas limitações poderão condicionar a generalização dos modelos desenvolvidos, pelo que se recomenda a aplicação futura a *datasets* mais alargados e diversificados, bem como a integração com registos clínicos eletrónicos.

Em síntese, conclui-se que o uso de ML na periodontologia constitui uma abordagem inovadora e promissora, capaz de contribuir para o avanço da medicina personalizada em saúde oral. Este trabalho fornece uma base sólida para investigações futuras, que deverão:

- alargar e diversificar a amostra;
- validar os modelos em diferentes populações;

- explorar a inclusão de dados multimodais (imagens radiográficas, genómicos e comportamentais em tempo real);
- avaliar a interpretabilidade clínica dos modelos;
- desenvolver *interfaces* de suporte à decisão clínica, integráveis em registos eletrónicos de saúde.

Desta forma, o presente trabalho não só abre caminho para a aplicação prática de ML no diagnóstico e prognóstico da DP, como também reforça o papel destas ferramentas digitais no apoio à prevenção e ao tratamento personalizado.

Bibliografia

Almyranti, M., Sutherland, E., Ash, N., and Eiszele, S. (2024). Oecd artificial intelligence papers. OCDE. Acedido em: 19 set. 2024.

Alqahtani, H. M., Koroukian, S. M., Stange, K., Schiltz, N. K., and Bissada, N. F. (2022). Identifying factors associated with periodontal disease using machine learning. *Journal of International Society of Preventive and Community Dentistry*, 12:612–620.

Ashwood, P., Krakowiak, P., Hertz-Picciotto, I., Hansen, R., Pessah, I., and de Water, J. V. (2011). Elevated plasma cytokines in autism spectrum disorders provide evidence of immune dysfunction and are associated with impaired behavioral outcome. *Brain, Behavior, and Immunity*, 25:40–45.

BinShabaib, M., ALHarthi, S. S., Akram, Z., Khan, J., Rahman, I., Romanos, G. E., and Javed, F. (2019). Clinical periodontal status and gingival crevicular fluid cytokine profile among cigarette-smokers, electronic-cigarette users and never-smokers. *Archives of Oral Biology*, 102:212–217.

Binson, V. A., Thomas, S., Subramoniam, M., Arun, J., Naveen, S., and Madhu, S. (2024). A review of machine learning algorithms for biomedical applications.

BioLegend (2025). Legendplex™ mull-analyte flow assay kit for accurate quantification of multiple human th (t helper cell) cytokines from cell culture supernatant, serum, plasma and other biological samples legendplex™ mull-analyte flow assay kit. Technical report.

Bishop, C. (2021). Time to take gum disease seriously: The societal and economic impact of periodontitis. The Economist Intelligence Unit Limited. Acedido em: 19 out. 2024.

Bohr, A. and Memarzadeh, K. (2020). *The rise of artificial intelligence in healthcare applications*, pages 25–60. Elsevier.

Cafiero, C., Spagnuolo, G., Marenzi, G., Martuscelli, R., Colamaio, M., and Leuci, S. (2021). Predictive periodontitis: The most promising salivary biomarkers for early diagnosis of periodontitis.

Cebesoy, E. I., Altaca, M., Kocak-Oztug, N. A., Bingül, I., and Cifcibasi, E. (2024). Associations between interleukin-10, -12, and – 18 and periodontal health and disease: a cross-sectional study. *Clinical Oral Investigations*, 28.

Centers for Disease Control and Prevention (2024). About periodontal (gum) disease. https://www.cdc.gov/oral-health/about/gum-periodontal-disease.html. Acedido em: 19 set. 2024.

Chang, M. C., Lin, S. I., Pan, Y. H., Lin, L. D., Wang, Y. L., Yeung, S. Y., Chang, H. H., and Jeng, J. H. (2019). Il-1β-induced icam-1 and il-8 expression/secretion of dental pulp cells is differentially regulated by irak and p38. *Journal of the Formosan Medical Association*, 118:1247–1254.

Chang, Y., Lee, J. S., Lee, K. J., Woo, H. G., and Song, T. J. (2020). Improved oral hygiene is associated with decreased risk of new-onset diabetes: a nationwide population-based cohort study. *Diabetologia*, 63:924–933.

Chapple, I. L., Mealey, B. L., Dyke, T. E. V., Bartold, P. M., Dommisch, H., Eickholz, P., Geisinger, M. L., Genco, R. J., Glogauer, M., Goldstein, M., Griffin, T. J., Holmstrup, P., Johnson, G. K., Kapila, Y., Lang, N. P., Meyle, J., Murakami, S., Plemons, J., Romito, G. A., Shapira, L., Tatakis, D. N., Teughels, W., Trombelli, L., Walter, C., Wimmer, G., Xenoudi, P., and Yoshie, H. (2018). Periodontal health and gingival diseases and conditions on an intact and a reduced periodontium: Consensus report of workgroup 1 of the 2017 world workshop on the classification of periodontal and peri-implant diseases and conditions. In *Journal of Clinical Periodontology*, volume 45, pages S68–S77. Blackwell Munksgaard.

Chen, M. (2024). What is machine learning? https://www.oracle.com/artificial-intelligence/machine-learning/what-is-machine-learning/. Acedido em: 21 out. 2024.

Ciobanu-Caraus, O., Aicher, A., Kernbach, J. M., Regli, L., Serra, C., and Staartjes, V. E. (2024). A critical moment in machine learning in medicine: on reproducible and interpretable learning.

Copeland, B. (2024). Artificial intelligence. https://www.britannica.com/technology/artificial-intelligence. Encyclopedia Britannica, Acedido em: 19 out. 2024.

Darby, I. (2022). Risk factors for periodontitis & peri-implantitis. *Periodontology 2000*, 90(1):9–12.

Deng, K., Zonta, F., Yang, H., Pelekos, G., and Tonetti, M. S. (2023). Development of a machine learning multiclass screening tool for periodontal health status based on non-clinical parameters and salivary biomarkers. *Journal of Clinical Periodontology*.

Devi, O. M., Sood, S., Gupta, J., and Jain, A. (2024). Prevalence and severity of periodontal disease and its association with type-ii diabetes mellitus and smoking by using periodontal screening and recording: A retrospective study. *Indian Journal of Community Medicine*, 49:53–56.

Dicembrini, I., Serni, L., Monami, M., Caliri, M., Barbato, L., Cairo, F., and Mannucci, E. (2020). Type 1 diabetes and periodontitis: prevalence and periodontal destruction—a systematic review.

Direção Geral da Saúde (2021). Programa nacional de promoção da saúde oral. `https://shorturl.at/DZip5`. Acedido em: 20 out. 2024.

Direção Geral da Saúde (2022). Plano nacional de saúde 2021-2030. `https://encr.pw/tCiFG`. Acedido em: 20 out. 2024.

Dixit, A., Dhanalakshmi, P., Rameshchandra, P. T., Chachlani, K. S., Dithi, C., Dash, K. C., Obulareddy, V. T., and Kamma, P. K. G. (2024). Effect of smoking cessation programs on periodontal disease progression. *Journal of Pharmacy and Bioallied Sciences*, 16:S774–S776.

Dyke, T. E. V. and Dave, S. (2005). Risk factors for periodontitis. *Journal of the International Academy of Periodontology*, 7(1):3–7. PMID: 15736889.

Ertaş, K., Pence, I., Cesmeli, M. S., and Ay, Z. Y. (2022). Determination of the stage and grade of periodontitis according to the current classification of periodontal and peri-implant diseases and conditions (2018) using machine learning algorithms. *Journal of Periodontal and Implant Science*, 52.

European Federation of Periodontology (2021). Gum diseases explained. `https://www.efp.org/for-patients/gum-diseases/gum-diseases-explained/`. Acedido em: 19 out. 2024.

Farina, R., Lopez, R., Simonelli, A., and Trombelli, L. (2023). Accuracy and applicability of periodontitis risk assessment tools: A critical appraisal.

Federação Internacional de Diabetes (2024). About diabetes. `https://idf.org/about-diabetes/what-is-diabetes/`. Acedido em: 20 out.2024.

Haber, J., Wattles, J., Crowley, M., Mandell, R., Joshipura, K., and Kent, R. L. (1993). Evidence for cigarette smoking as a major risk factor for periodontitis. *Journal of Periodontology*, 64:16–23.

Hasan, A. and Palmer, R. M. (2014). A clinical guide to periodontology: Pathology of periodontal disease.

Hasan, N. W. M., Baharin, B., Mohd, N., Rahman, M. A., and Hassan, N. (2024). Comparative effects of e-cigarette smoking on periodontal status, salivary ph, and cotinine levels. *BMC Oral Health*, 24.

Kudiyirickal, M. G. and Pappachan, J. M. (2024). Periodontitis: An often-neglected complication of diabetes. *World Journal of Diabetes*, 15:318–325.

Lang, N. P., Schätzle, M. A., and Löe, H. (2009). Gingivitis as a risk factor in periodontal disease. *Journal of Clinical Periodontology*, 36:3–8.

Li, W., Xia, Y., Yang, J., Sanyal, A. J., Shah, V. H., Chalasani, N. P., and Yu, Q. (2024). Disrupted balance between pro-inflammatory lipid mediators and anti-inflammatory specialized pro-resolving mediators is linked to hyperinflammation in patients with alcoholic hepatitis. *Frontiers in Immunology*, 15.

Majeed, M. M., Ahmed, I., Roome, T., Alali, Y., Al-Aali, K. A., Ahmed, N., Saleem, Z., Alhumaidan, A. A., Farooqui, W. A., Ahmed, S., Vohra, F., and Abduljabbar, T. (2022). Association of the unstimulated whole salivary cytokine il-1levels with initial, moderate and severe periodontitis. a case control study. *International Journal of Environmental Research and Public Health*, 19.

Manzardo, A. M., Poje, A. B., Penick, E. C., and Butler, M. G. (2016). Multiplex immunoassay of plasma cytokine levels in men with alcoholism and the relationship to psychiatric assessments. *International Journal of Molecular Sciences*, 17.

Marotz, C., Molinsky, R., Martino, C., Bohn, B., Roy, S., Rosenbaum, M., Desvarieux, M., Yuzefpolskaya, M., Paster, B. J., Jacobs, D. R., Colombo, P. C., Papapanou, P. N., Knight, R., and Demmer, R. T. (2022). Early microbial markers of periodontal and cardiometabolic diseases in origins. *npj Biofilms and Microbiomes*, 8.

Marr, B. (2018). How is ai used in healthcare - 5 powerful real-world examples that show the latest advances. `https://www.forbes.com/sites/ehealth/2024/11/12/in-person-online-with-todays-medicare-beneficiaries/?` Acedido em: 1 nov. 2024.

McCarthy, J. (s.d.). John mccarthy's home page. `https://www-formal.stanford.edu/jmc/`. Acedido em: 19 out. 2024.

Mohajeri, A., Lipsky, M. S., Hegde, R., Chiang, J., and Hung, M. (2024). Electronic nicotine delivery systems use and periodontal health—findings from the population assessment of tobacco and health study. *Healthcare (Switzerland)*, 12.

National Institute of Dental and Craniofacial Research (2024). Probing periodontal disease. https://www.nidcr.nih.gov/news-events/nidcr-news/2024/probing-periodontal-disease. Acedido em: 21 out. 2024.

Oracle (2023). Improve value-based care with performance monitoring. https://www.oracle.com/data-platform/optimize-medical-staff-workloads/. Acedido em: 25 out. 2024.

Organização Mundial da Saúde (2023). Oral health. https://www.who.int/news-room/fact-sheets/detail/oral-health. Acedido em: 10 nov. 2024.

Ozden, F. O., Özgönenel, O., Özden, B., and Aydogdu, A. (2015). Diagnosis of periodontal diseases using different classification algorithms: A preliminary study. *Nigerian Journal of Clinical Practice*, 18:416–421.

Papapanou, P. N., Sanz, M., Buduneli, N., Dietrich, T., Feres, M., Fine, D. H., Flemmig, T. F., Garcia, R., Giannobile, W. V., Graziani, F., Greenwell, H., Herrera, D., Kao, R. T., Kebschull, M., Kinane, D. F., Kirkwood, K. L., Kocher, T., Kornman, K. S., Kumar, P. S., Loos, B. G., Machtei, E., Meng, H., Mombelli, A., Needleman, I., Offenbacher, S., Seymour, G. J., Teles, R., and Tonetti, M. S. (2018). Periodontitis: Consensus report of workgroup 2 of the 2017 world workshop on the classification of periodontal and peri-implant diseases and conditions. In *Journal of Clinical Periodontology*, volume 45, pages S162–S170. Blackwell Munksgaard.

Polinski, K. J., Bemis, E. A., Yang, F., Crume, T., Demoruelle, M. K., Feser, M., Seifert, J., O'Dell, J. R., Mikuls, T. R., Weisman, M. H., Gregersen, P. K., Keating, R. M., Buckner, J., Reisdorph, N., Deane, K. D., Clare-Salzler, M., Holers, V. M., and Norris, J. M. (2021). Association of lipid mediators with development of future incident inflammatory arthritis in an anti–citrullinated protein antibody–positive population. *Arthritis and Rheumatology*, 73:955–962.

Preshaw, P. M. and Bissett, S. M. (2019). Periodontitis and diabetes. *British Dental Journal*, 227:577–584.

Ramadan, D. E., Hariyani, N., Indrawati, R., Ridwan, R. D., and Diyatri, I. (2020). Cytokines and chemokines in periodontitis.

Rashid, M. E., Alam, M. K., Akhter, K., Abdelghani, A., Babkair, H. A., and Sghaireen, M. G. (2024). Assessing the impact of smoking cessation interventions on periodontal health and gingival inflammation in smokers with periodontitis. *Journal of Pharmacy and Bioallied Sciences*, 16:S745–S747.

Relvas, M., Mendes-Frias, A., Gonçalves, M., Salazar, F., López-Jarana, P., Silvestre, R., and da Costa, A. V. (2024). Salivary il-1, il-6, and il-10 are key biomarkers of periodontitis severity. *International Journal of Molecular Sciences*, 25.

Sarker, I. H. (2021). Machine learning: Algorithms, real-world applications and research directions. *SN Computer Science*, 2.

Schober, P. and Vetter, T. R. (2021). Logistic regression in medical research. *Anesthesia & Analgesia*, 132(2):365–366.

Shabil, M., Khatib, M. N., Ballal, S., Bansal, P., Tomar, B. S., Ashraf, A., Kumar, M. R., Sinha, A., Rawat, P., Gaidhane, A. M., Sah, S., Bushi, G., Singh, M. P., Bhopte, K., Dziedzic, A., and Pant, M. (2024). The impact of electronic cigarette use on periodontitis and periodontal outcomes: a systematic review and meta-analysis. *BMC oral health*, 24:1197.

Steffens, J. P. and Marcantonio, R. A. C. (2018). Classificação das doenças e condições periodontais e peri-implantares 2018: guia prático e pontos-chave. *Revista de Odontologia da UNESP*, 47:189–197.

Uddin, S., Khan, A., Hossain, M. E., and Moni, M. A. (2019). Comparing different supervised machine learning algorithms for disease prediction. *BMC Medical Informatics and Decision Making*, 19.

Zdrok, O. (2024). Why "garbage in, garbage out" should be the new mantra for ai implementation. `https://shelf.io/blog/garbage-in-garbage-out-ai-implementation/`. Acedido em: 1 nov. 2024.

Zhang, M., Liu, Y., Afzali, H., and Graves, D. T. (2024). An update on periodontal inflammation and bone loss. *Frontiers in Immunology*, 15.

Parte IV
Apêndices

Apêndice A
Parâmetros do Modelo de Regressão Logística

Para permitir total reprodutibilidade do modelo de Regressão Logística com *Top Features*, apresentam-se as médias e desvios padrão usados na normalização das variáveis (Tabela 10).

A.1 Média e desvio padrão das variáveis (`StandardScaler`)

Tabela 10: Média e desvio padrão de cada variável usada pelo modelo.

Variável	Média	Desvio padrão
Percentagem total de sangramento à sondagem	20.0832	18.6329
Profundidade de sondagem total (mm)	2.1734	0.8136
Percentagem total do índice de placa	33.3635	26.7510
log(IL-8 (B7))	5.6669	1.0286
Número de cigarros por dia	1.7886	4.4152
log(IL-1β (A7))	5.5541	0.9553
Número total de dentes	27.2483	4.1610
log(IL-6 (B3))	2.6075	1.3047
Frequência de escovagem diária	2.2886	0.7263
log(MCP-1 (A10))	5.1873	0.9074

Para cada marcador inflamatório, aplica-se primeiro a transformação logarítmica natural de forma ajustada (`log1p`), obtendo-se $\log(1+x)$. Em seguida, cada variável é normalizada usando os parâmetros da Tabela 10 segundo a fórmula do z-score:

$$x_{\text{norm}} = \frac{\log(1+x) - \mu}{\sigma},$$

onde μ e σ correspondem à média e ao desvio padrão da variável, respetivamente, e x_{norm} é o valor normalizado utilizado no cálculo de z e da probabilidade $P = \frac{1}{1+e^{-z}}$ para novos utentes.

Apêndice B
Ferramentas

O desenvolvimento do presente estudo contou com recurso às seguintes ferramentas:

- **Linguagem de Programação:**
  - Python 3.12.7 (Anaconda Distribution).
- **Ambiente de Desenvolvimento:**
  - Jupyter Notebook (para análise de dados, treino dos algoritmos e execução de modelos).
- **Bibliotecas Principais:**
  - NumPy – operações matemáticas e manipulação de arrays.
  - Pandas – tratamento e análise de dados.
  - Matplotlib – visualização gráfica.
  - Scikit-learn – implementação de modelos de machine learning e métricas de avaliação.
- **Armazenamento de Código:**
  - GitHub – armazenamento da parte prática da tese (projeto acessível em: *https://-github.com/joanalopes7/Análise-de-fatores-de-risco-e-previsão-da-doença-periodontal-com-recurso-a-Machine-Learning-.git*)
- **Redação e Formatação da Tese:**
  - LaTeX.